# 심층 신경망

DNN (Deep Neural Networks)

# 학습 목표

- 심층 신경망의 구조를 이해한다.
- 은닉층의 역할을 이해한다.
- **그래디언트 소실 문제**를 이해한다.
- 새로 등장한 여러 가지 활성화 함수를 이해한다.
- **다양한 손실 함수**를 이해한다.

# 심층신경망 (DNN)

- 심층 신경망(**DNN: Deep Neural Networks**)은 MLP(다층 퍼셉트론)에서 은닉층의 개수를 증가시킨 것이다.
- **은닉층을 하나만 사용하는 것이 아니고 여러 개를 사용**한다.
- 최근에 딥러닝은 컴퓨터 시각, 음성 인식, 자연어 처리, 소셜 네트워크 필터링, 기계 번역 등에 적용되어서 인간 전문가에 필적하는 결과를 얻고 있다.

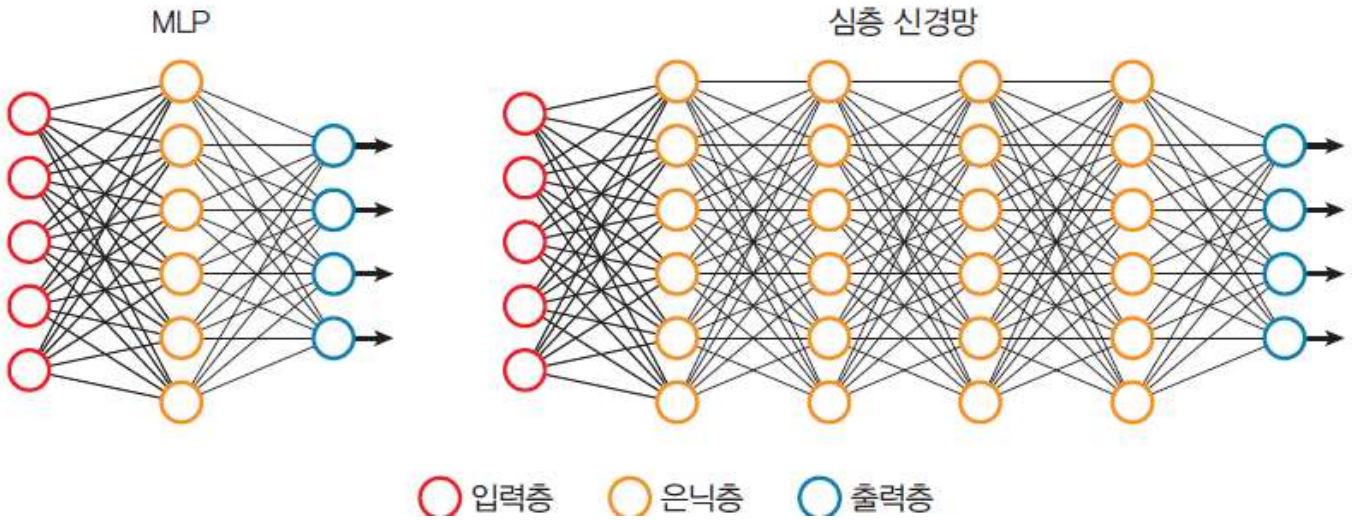

# MLP의 문제점 해결

- 은닉층이 많아지면 출력층에서 계산된 그래디언트가 역전파되다가 값이 점점 작아져서 없어지는 문제점 -> 해결
- 훈련 데이터가 충분하지 못하면, 과잉 적합(over fitting)이 될 가능성도 높아진다. -> 해결
- 2012년에는 AlexNet이 다른 머신러닝 방법들을 큰 차이로 물리치고 ImageNet 경진대회에서 우승한다.

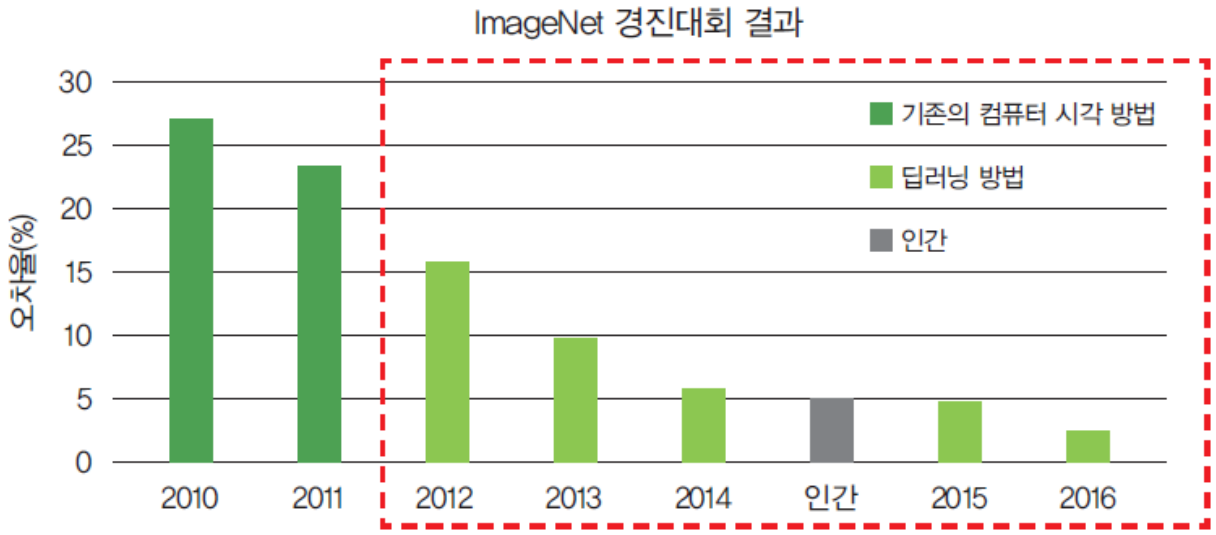

# GPU의 도움

- DNN의 학습 속도는 상당히 느리고 계산 집약적이 기 때문에 학습에 시간과 자원이 많이 소모되었다.
- 최근 **GPU(Graphic Processor Unit)** 기술이 엄청나게 발전하면서 GPU가 제공하는 데이터 처리 기능을 딥러닝도 사용할 수 있게 되었다. 딥러닝 혁명에는 게임머들의 도움도 컸다.

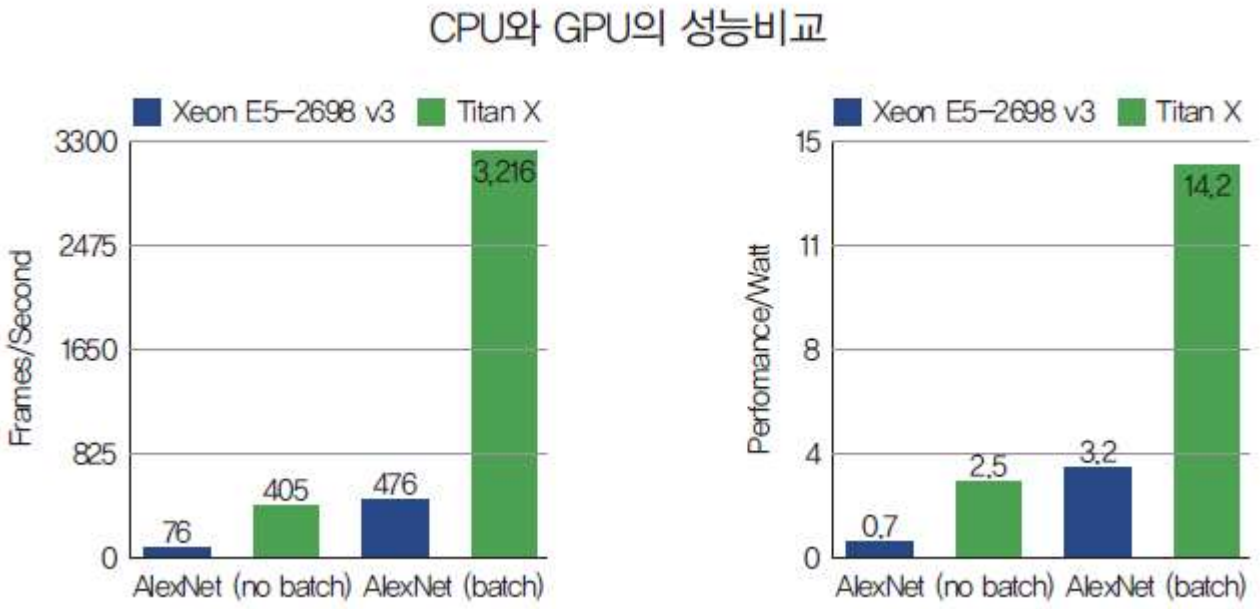

# 은닉층의 역할: 에지 → 부분 객체 → 객체

- 은닉층은 무슨 역할을 하고 있는 것일까? -> 여러 개의 은닉층 중에서 앞단은 **경계선(에지)**과 같은 저급 특징들을 추출하고 뒷단은 **부분 객체, 객체**와 같은 고급 특징들을 추출한다.

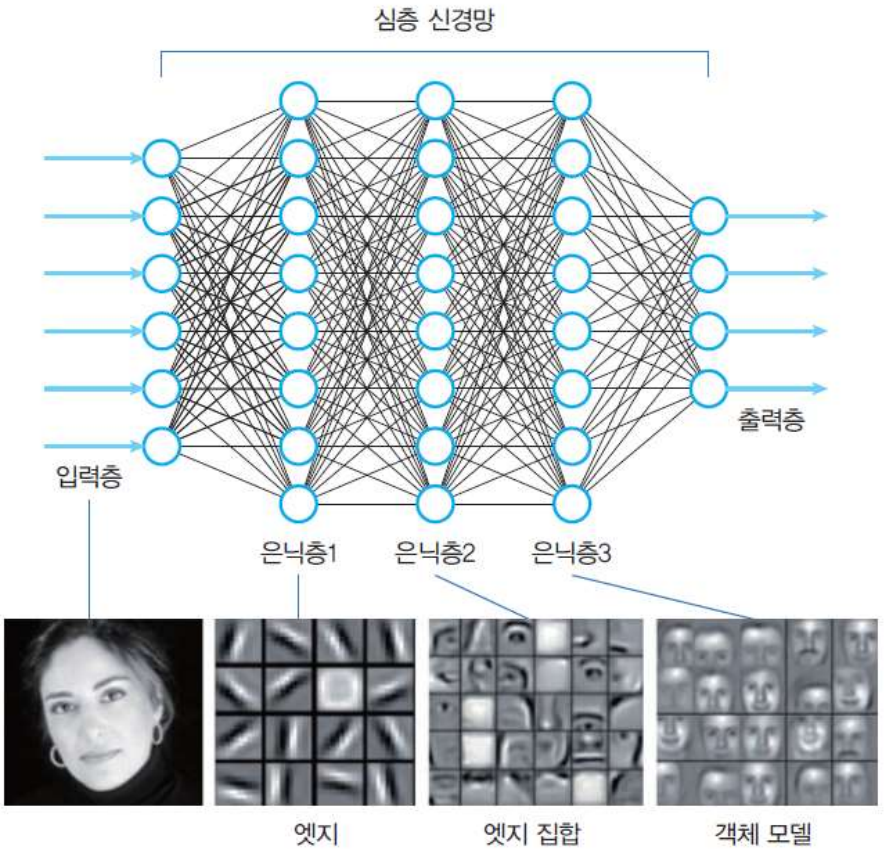

# MLP vs DNN

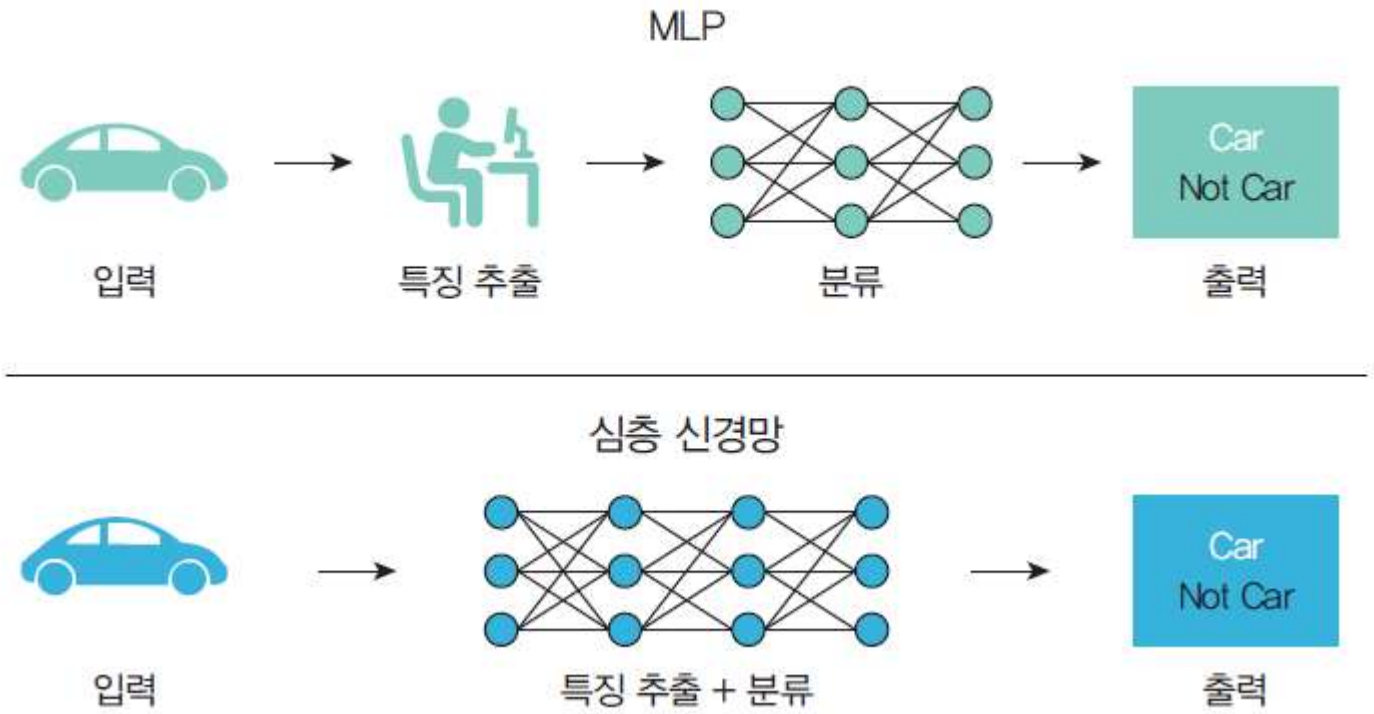

# 그래디언트 소실 문제

- 심층 신경망에서 그래디언트가 전달되다가 점점 0에 가까워지는 현상이다

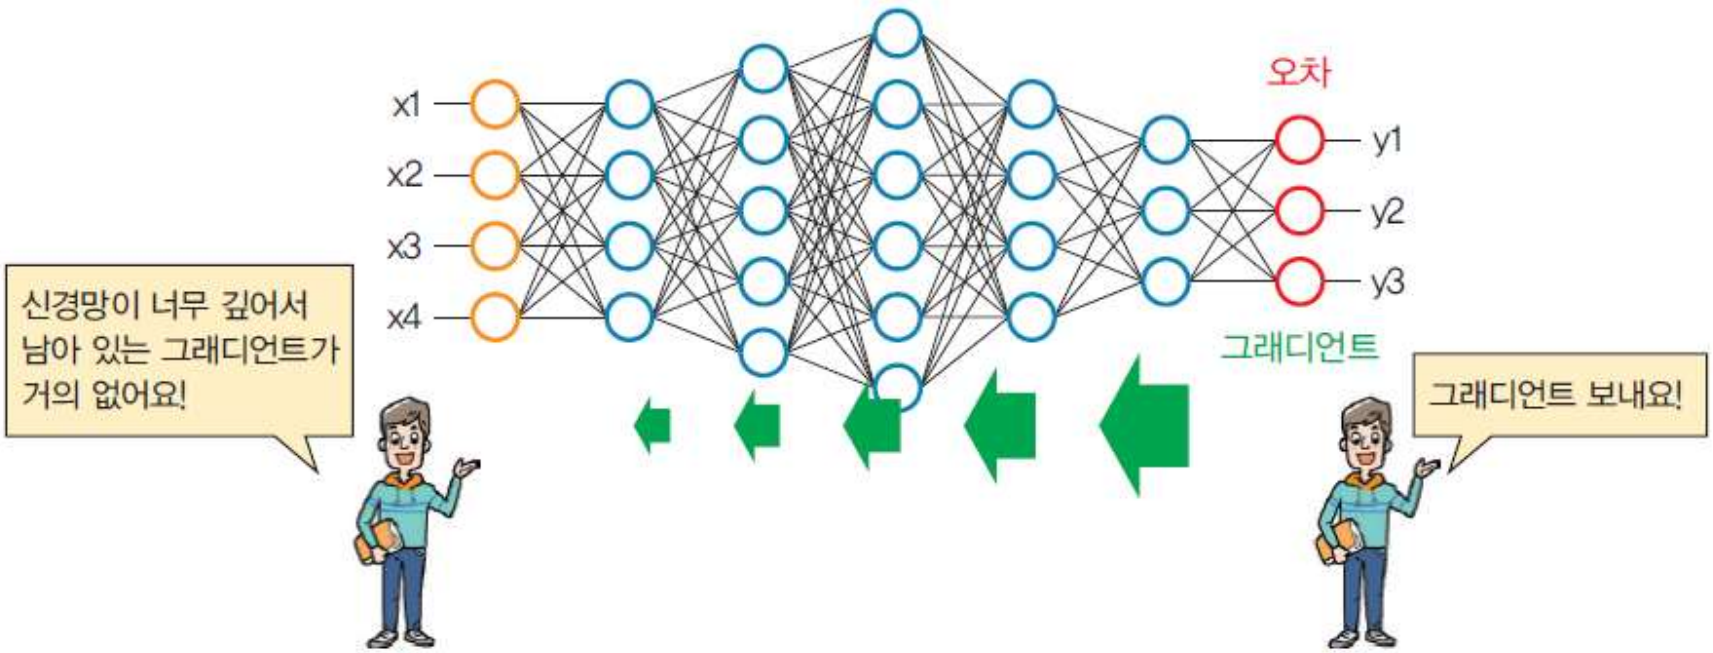

# 범인은?

- 범인은 시그모이드 활성화 함수로 드러난다.
- 시그모이드 함수의 특성상, 아주 큰 양수나 음수가 들어오면 출력이 포화되어서 거의 **0**이 된다.

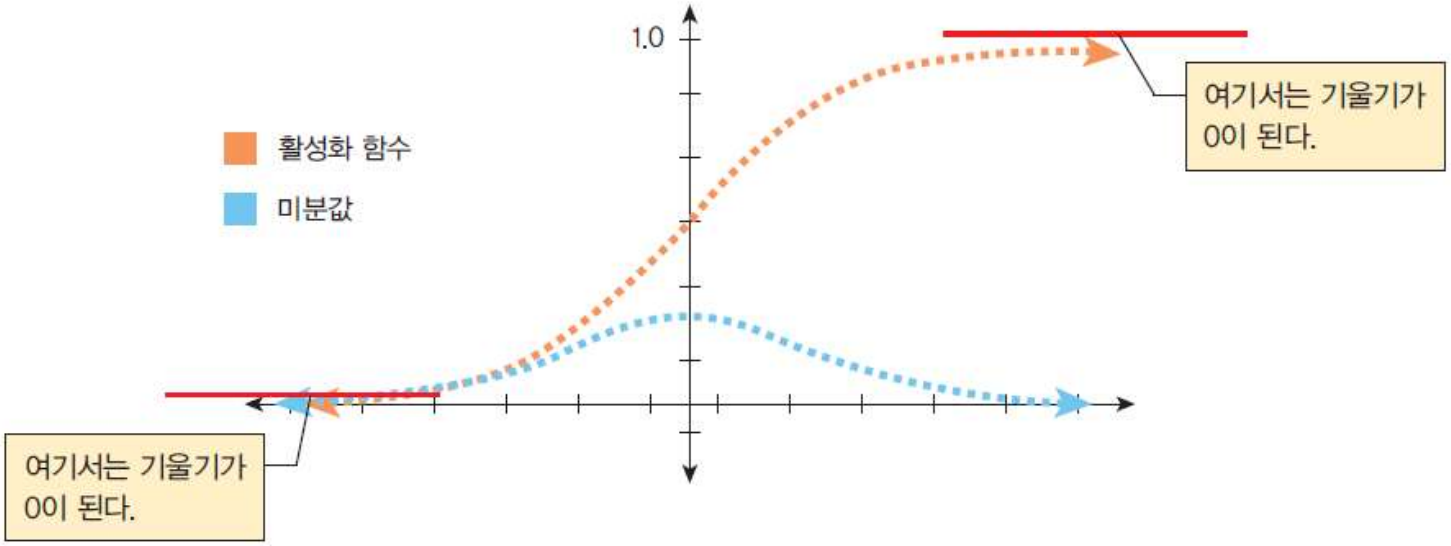


그림 8-5 시그모이드 함수와 그래디언트 소실

# 역전파 알고리즘의 복습: vanishing gradient

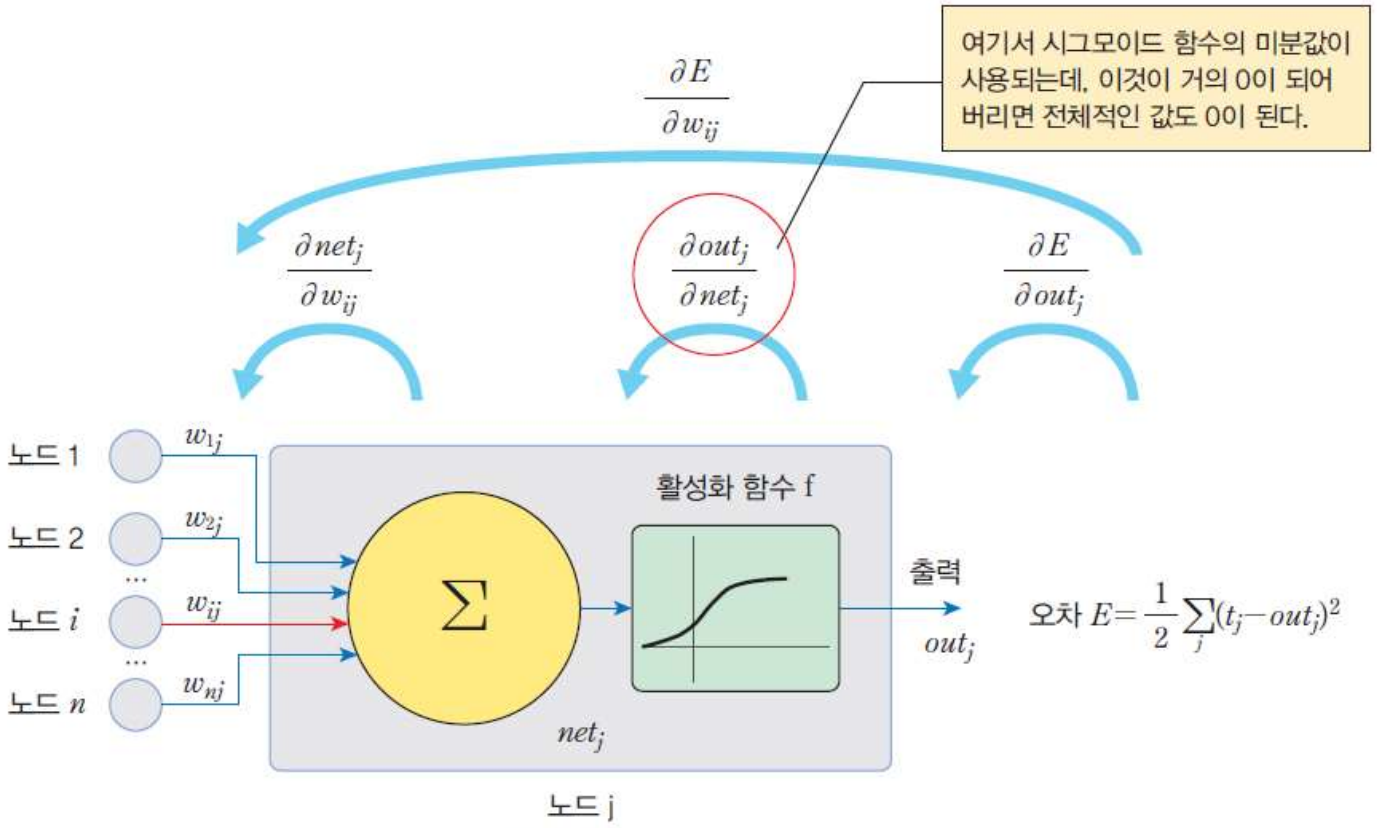


그림 8-6 그래디언트 소실 문제

# 새로운 활성화 함수

- 그래디언트 소실 문제를 해결하기 위하여 심층 신경망에서는 활성화 함수로 **ReLU 함수**를 많이 사용한다.

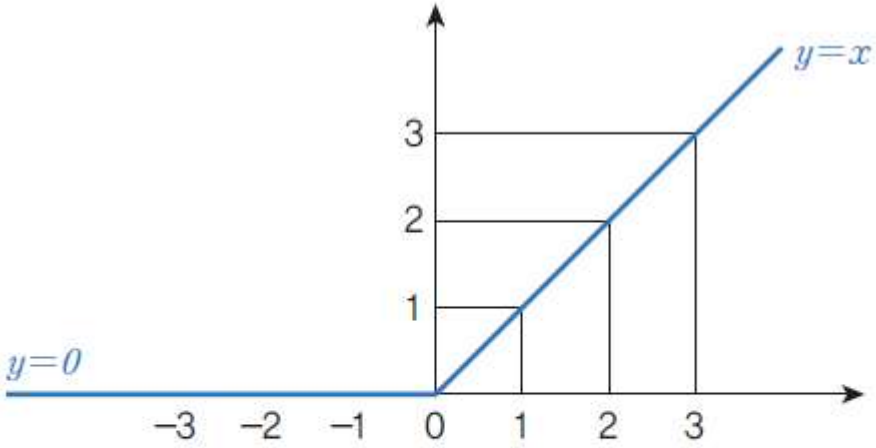


$$f(x)=\begin{cases} x & (x>0) \\ 0 & (x\le 0) \end{cases}$$

그림 8-7 ReLU 함수

# Lab: 활성화 함수 실험

- https://playground.tensorflow.org로 실험

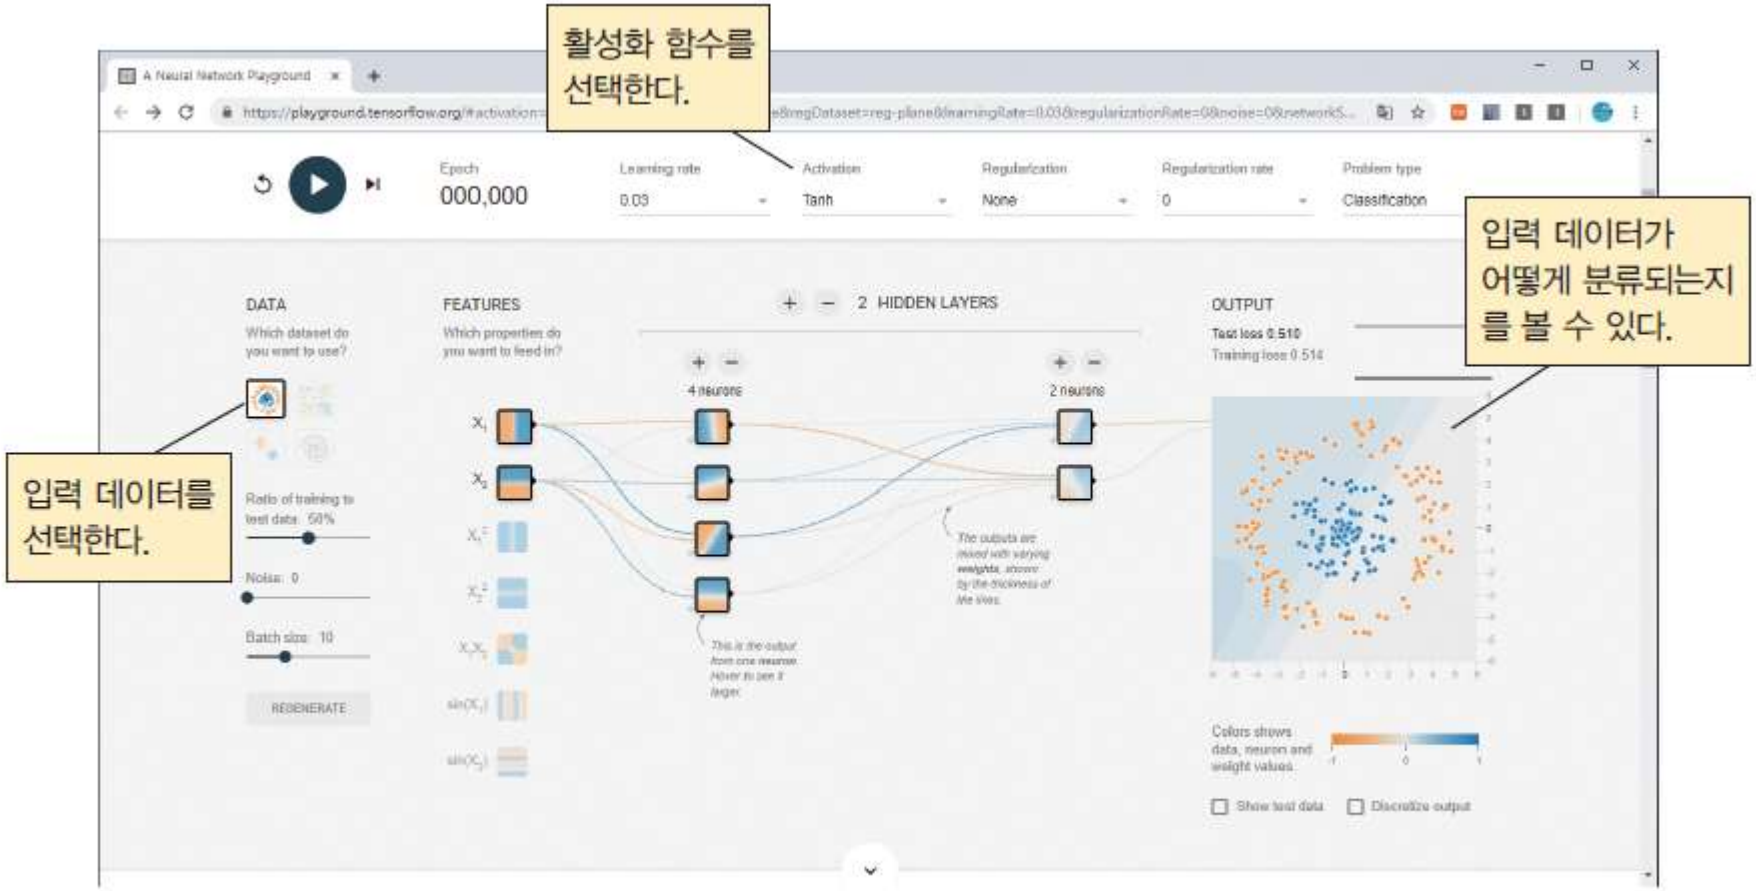

# 다양한 활성화 함수 변경

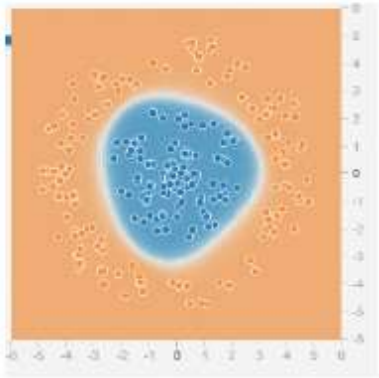

tanh

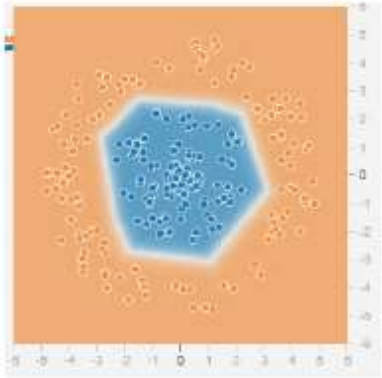

ReLU

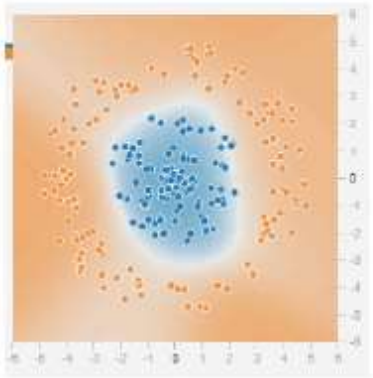

Sigmoid

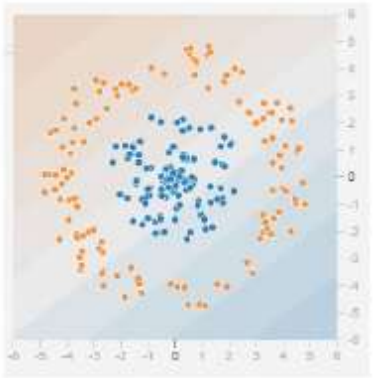

Linear

# 손실 함수 선택 문제

- 손실 함수로는 이제까지는 평균 제곱 오차(Mean Squared Error: MSE)를 사용

$$E = \frac{1}{m}\sum(y_i - \hat{y}_i)^2$$

- 정답과 예측값의 차이가 커지면 MSE도 커지므로 충분히 사용할 수 있는 손실 함수이다.
- 하지만 분류 문제를 위해서는 **MSE보다는 더 성능이 좋은 손실 함수가 개발**되어 있다.

# 소프트맥스(softmax) 활성화 함수

- "소프트맥스"라는 이름이 붙은 이유는 이것이 max 함수의 소프트한 버전이기 때문이다. Max 함수의 출력은 전적으로 최대 입력값에 의하여 결정된다

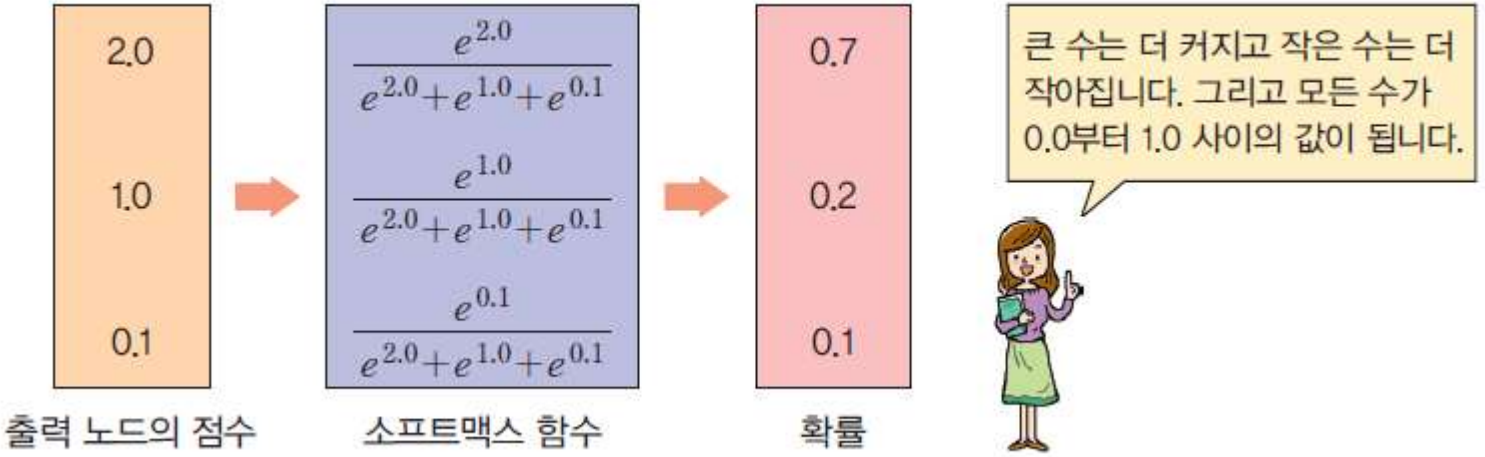

# 교차 엔트로피 손실 함수 : cross-entropy

- 교차 엔트로피는 2개의 확률 분포 p, q에 대해서 다음과 같이 정의된다.

$$H(p, q) = -\sum_{x} p(x) \log_n q(x)$$

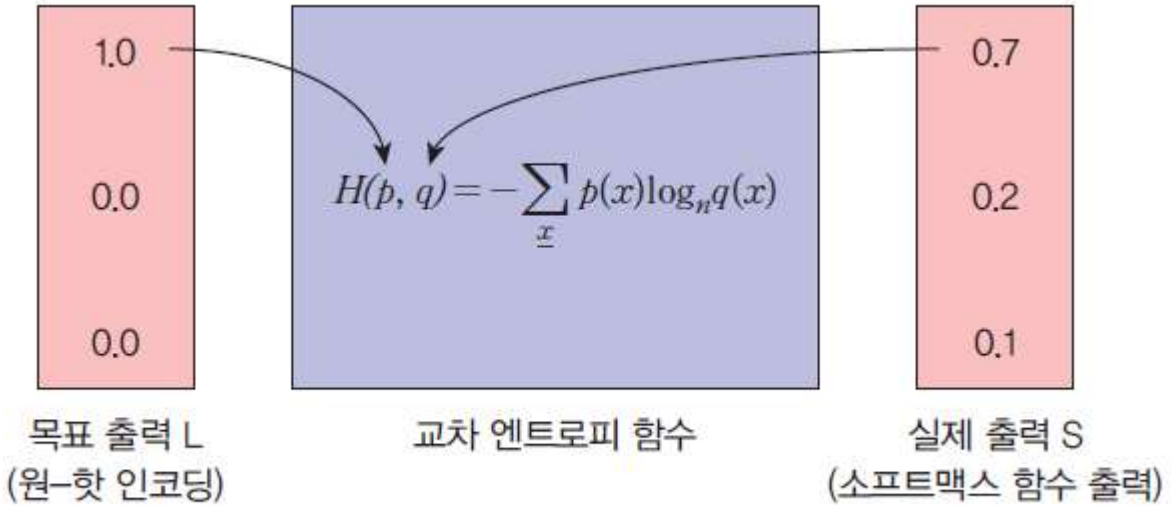


그림 8-9 교차 엔트로피 함수

# 교차 엔트로피 손실 함수

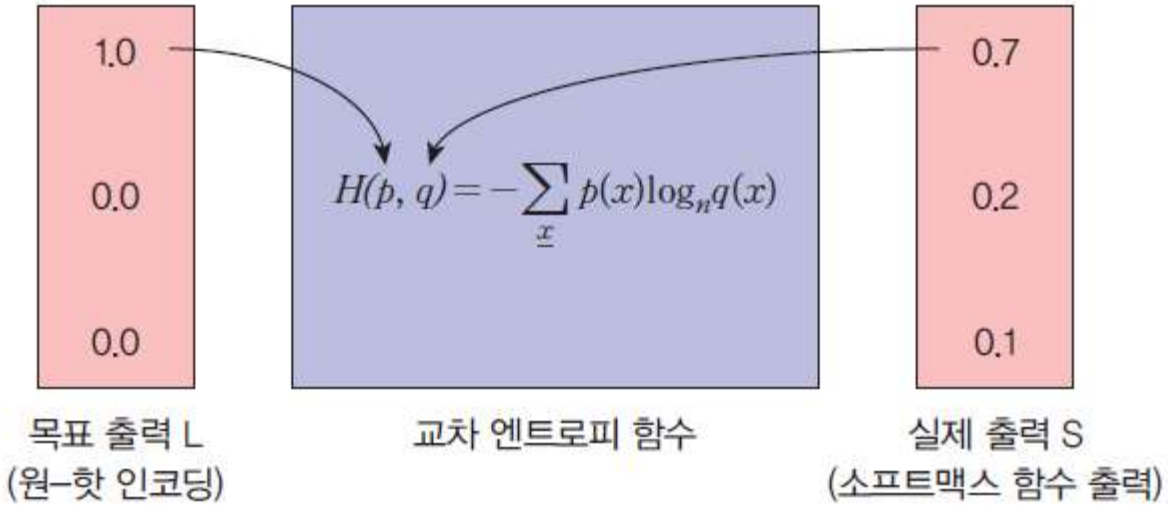


그림 8-9 교차 엔트로피 함수

$$
\begin{aligned}
H(p, q) &= -\sum_x p(x)\log_n q(x) \\
&= -(1.0 * \log 0.7 + 0.0 * \log 0.2 + 0.0 * \log 0.1) \\
&= 0.154901
\end{aligned}
$$

# 완벽하게 일치한다면

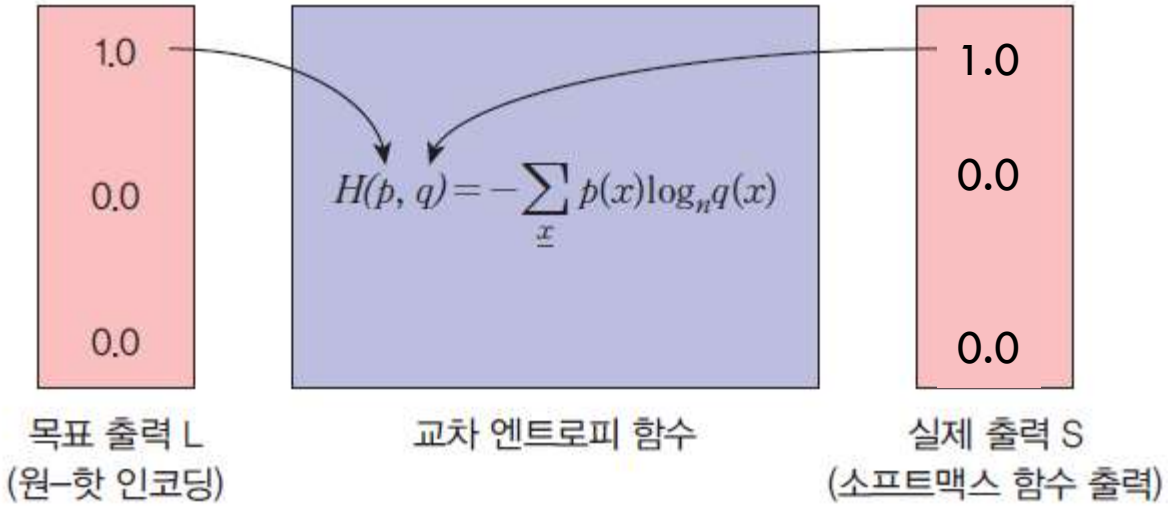


그림 8-9 교차 엔트로피 함수

$$
\begin{aligned}
H(p, q) &= -\sum_x p(x)\log_n q(x) \\
&= -(1.0 * \log 1.0 + 0.0 * \log 0.0 + 0.0 * \log 0.0) \\
&= 0
\end{aligned}
$$

# Lab: 교차 엔트로피의 계산

| 입력 샘플 | 실제 출력 | | | 목표 출력 | | |
|---|---|---|---|---|---|---|
| 샘플 #1 | 0.1 | 0.3 | 0.6 | 0 | 0 | 1 |
| 샘플 #2 | 0.2 | 0.6 | 0.2 | 0 | 1 | 0 |
| 샘플 #3 | 0.3 | 0.4 | 0.3 | 1 | 0 | 0 |

▷ 첫 번째 샘플에 대하여 교차 엔트로피를 계산해보자. -(log(0.1) * 0 + log(0.3) * 0 + log(0.6) * 1) = -(0 + 0 - 0.51) = 0.51이 된다.

▷ 두 번째 샘플의 교차 엔트로피는 -(log(0.2) * 0 + log(0.6) * 1 + log(0.2) * 0) = -(0 - 0.51 + 0) = 0.51이다.

▷ 세 번째 샘플의 교차 엔트로피는 -(log(0.3) * 1 + log(0.4) * 0 + log(0.3) * 0) = -(-1.2 + 0 + 0) = 1.20이다.

▷ 따라서 3개 샘플의 평균 교차 엔트로피 오류는 (0.51 + 0.51 + 1.20) / 3 = 0.74가 된다.

# 평균 제곱 오차 vs 교차 엔트로피

- 문제를 간단히 하기 위하여 출력 유닛이 하나인 경우만 생각하자
  - 평균 제곱 오차: $E = (y - \hat{y}_i)^2$
  - 이진 교차 엔트로피: $E = -[y \log_n(\hat{y}) + (1-y)\log_n(1-\hat{y})]$
  - 평균 제곱 오차(MSE): $E = \hat{y}_i^2$ (정답이 0일 때)

    $E = (1-\hat{y}_i)^2$ (정답이 1일 때)

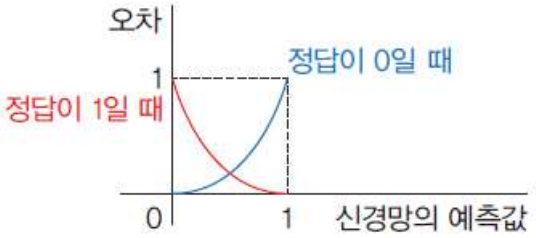


  - 이진 교차 엔트로피(BCE) 오차: $E = -\log_n(1-\hat{y})$ (정답이 0일 때)

    $E = -\log_n(\hat{y})$ (정답이 1일 때)

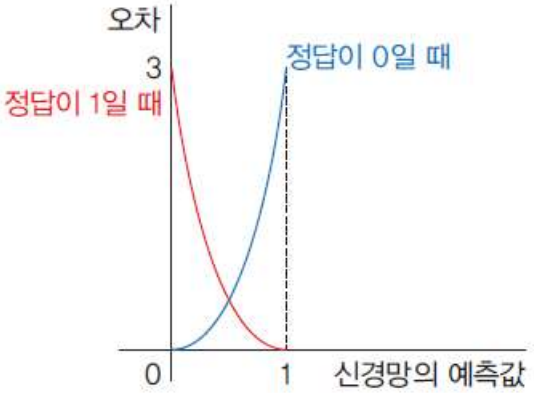

# 평균 제곱 오차 vs 교차 엔트로피 : Graph

**graph_mse_bce.py**

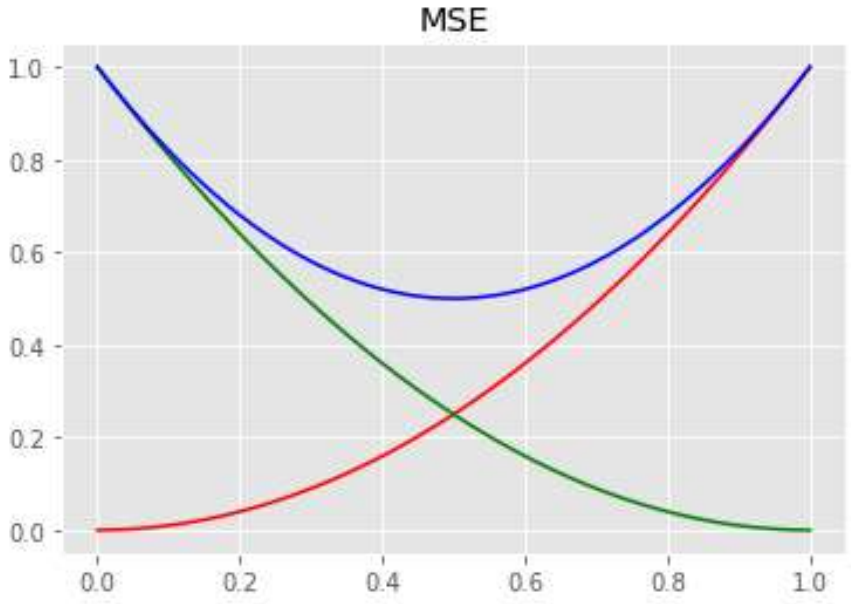


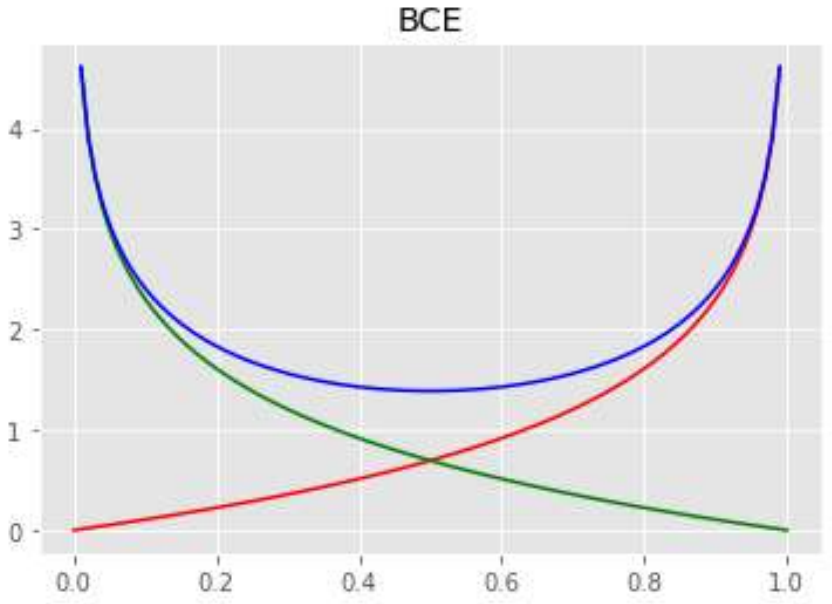


https://towardsdatascience.com/understanding-binary-cross-entropy-log-loss-a-visual-explanation-a3ac6025181a

# 케라스에서 손실함수 - BinaryCrossentropy

- **BinaryCrossentropy**: 이진 교차 엔트로피(BCE)는 이진 분류 문제를 해결하는 데 사용되는 손실 함수이다.
- 즉 우리가 분류해야 하는 부류가 두 가지뿐일 때 사용한다. 예를 들어 이미지를 "강아지", "강아지 아님"의 두 부류로 분류할 때 BinaryCrossentropy를 사용한다.

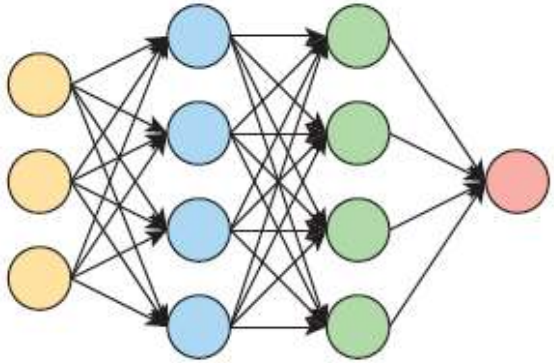

1 → 강아지
0 → 강아지 아님

$$BCE = -\frac{1}{n}\sum_{i=1}^{n}(y_i \log_n(\hat{y}_i) + (1-y_i)\log_n(1-\hat{y}_i))$$

# 실제 계산예

| 실제 레이블 y | 1 | 0 | 0 | 1 |
|---|---|---|---|---|
| 예측 값 ŷ | 0.8 | 0.3 | 0.5 | 0.9 |

$$\text{샘플 1}: \ BCE1 = -(1 \cdot \log(0.8) + (1-1) \cdot \log(1-0.8))$$
$$\text{샘플 2}: \ BCE2 = -(0 \cdot \log(0.3) + (1-0) \cdot \log(1-0.3))$$
$$\text{샘플 3}: \ BCE3 = -(0 \cdot \log(0.5) + (1-0) \cdot \log(1-0.5))$$
$$\text{샘플 4}: \ BCE4 = -(1 \cdot \log(0.9) + (1-1) \cdot \log(1-0.9))$$

$$BCE = \frac{BCE1 + BCE2 + BCE3 + BCE4}{4} \approx 0.345$$

```
y_true = [  [1],   [0],   [0],   [1]]
y_pred = [[0.8], [0.3], [0.5], [0.9]]
bce = tf.keras.losses.BinaryCrossentropy()
print(bce(y_true, y_pred).numpy())
```

```
0.3445814
```

# 다중 분류 : CategoricalCrossentropy

- **CategoricalCrossentropy**: 우리가 분류해야 할 부류가 두 개 이상이라면(즉 다중 분류 문제라면) 을 사용
- 정답 레이블은 원-핫 인코딩으로 제공한다. 예를 들어서 입력 이미지를 **"강아지(1,0, 0)", "고양이(0, 1, 0)", "호랑이(0, 0, 1)"** 중의 하나로 분류

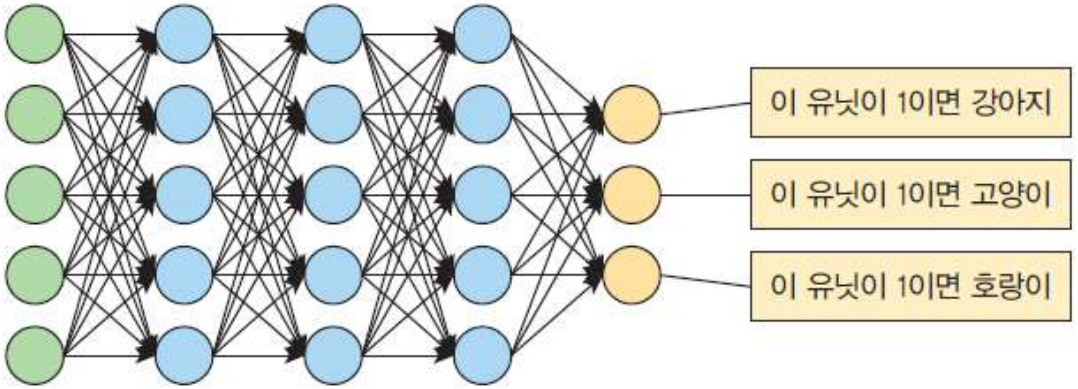


```
y_true = [[0.0, 1.0, 0.0], [0.0, 0.0, 1.0], [1.0, 0.0, 0.0]] # 고양이, 호랑이, 강아지
y_pred = [[0.6, 0.3, 0.1], [0.3, 0.6, 0.1], [0.1, 0.7, 0.2]]
cce = tf.keras.losses.CategoricalCrossentropy ()
print(cce(y_true, y_pred).numpy ())
```

```
1.936381
```

**keras_cross_ent_A.py**

# SparseCategoricalCrossentropy

- SparseCategoricalCrossentropy: 정답 레이블이 원-핫 인코딩이 아니고 정수로 주어지면 **SparseCategoricalCrossentropy**를 사용
- 예를 들어서 정답 레이블이 **0(강아지), 1(고양이), 2(호랑이)**로 주어지면 SparseCategoricalCrossentropy를 사용한다.

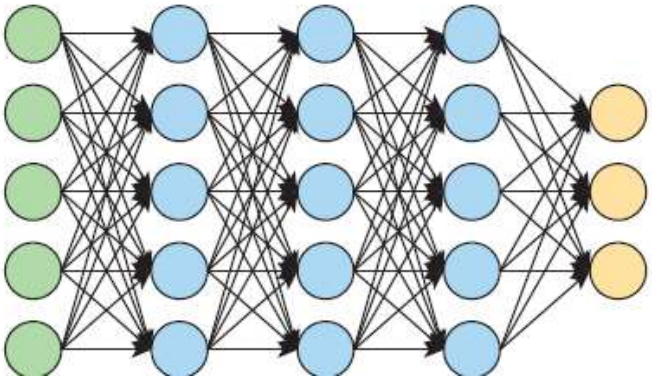

강아지이면 0
고양이이면 1
호랑이이면 2

케라스가 자동으로 원-핫 인코딩으로 변환한다.

```
y_true = [1, 2, 0]                                  # 고양이, 호랑이, 강아지
y_pred = [[0.6, 0.3, 0.1], [0.3, 0.6, 0.1], [0.1, 0.7, 0.2]]
scce = tf.keras.losses.SparseCategoricalCrossentropy()
print(scce(y_true, y_pred).numpy())
```

```
1.936381
```

# 가중치 초기화 문제

- 가중치의 초기값도 성능에 많은 영향을 끼친다. 신경망의 초기에는 연구가 부족하여서 초기값을 0으로 주는 경우도 많았다. -> 오차의 역전파가 되지 않는다.

$$\delta_j = \begin{cases} (out_j - t_j) f'(\text{net}_j) & \text{j가 출력층 노드이면} \\ (\sum_k w_{jk}\delta_k) f'(\text{net}_j) & \text{j가 은닉층 노드이면} \end{cases}$$

가중치가 0이라면 델타가 전달되지 않는다.

# 가중치 초기화 문제

- 가중치 w1, w2, w3, w4와 가중치 w5, w6, w7, w8이 모두 같은 값(예를 들어서 0.2)으로 설정되어 있다면, 노드 E와 노드 G는 완벽하게 동일한 일을 하게 된다. 이것을 방지하는 것을 "균형 깨뜨리기(breaking the symmetry)"라고 부르고 있다.

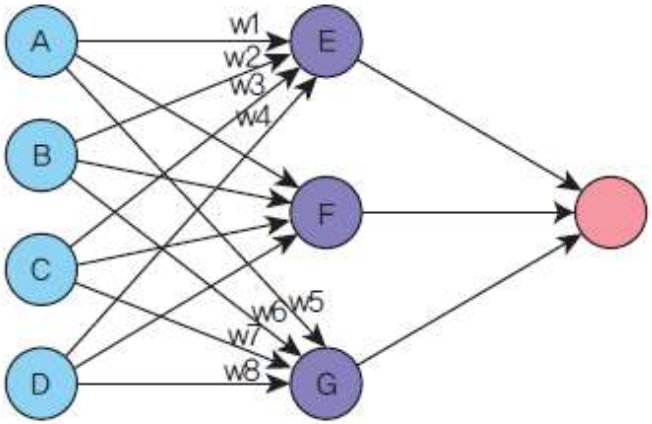


그림 8-10 가중치가 동일할 때의 문제점

# 난수 가중치 초기값 - Xavier의 방법

- 이상과 같은 이유로 가중치의 초기값은 난수로 결정되어야 한다.
- 또 반대로 너무 큰 가중치는 그래디언트 폭발(exploding gradients)을 일으킨다고 한다. 이 경우에는 학습이 수렴하지 않고 발산하게 된다
- Xavier의 방법

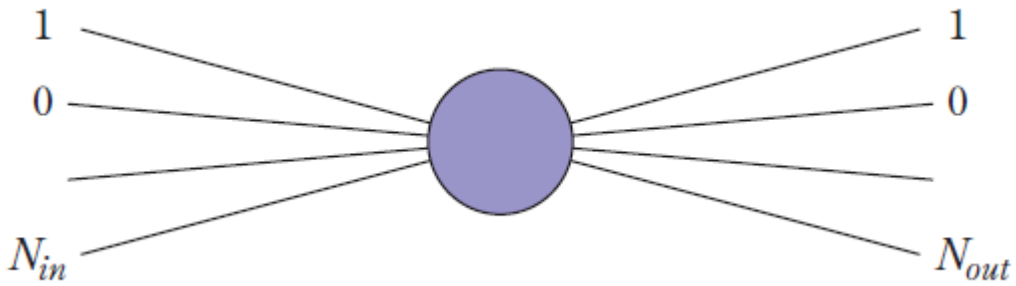


$$var(w_i) = \frac{1}{N_{in}}$$

# 난수 가중치 초기값 - He의 방법

- He의 방법

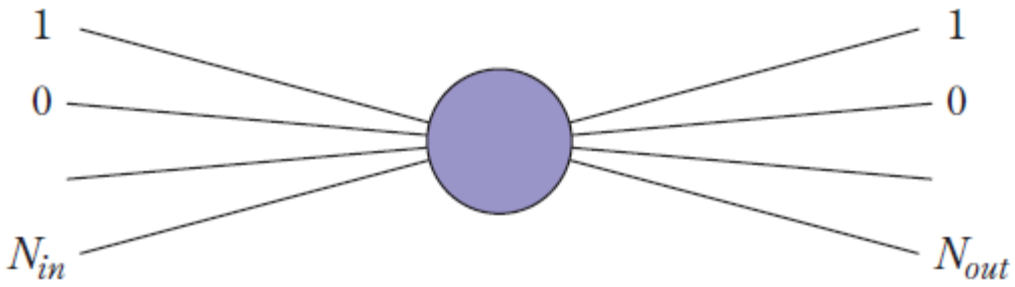


$$var(w_i) = \frac{2}{(N_{in} + N_{out})}$$

# Lab: 가중치 초기화 실험

- https://www.deeplearning.ai/ai-notes/initialization/에 가보면 여러분들은 다양한 초기값을 가지고 오차가 얼마나 빨리 줄어드는지를 볼 수 있다.

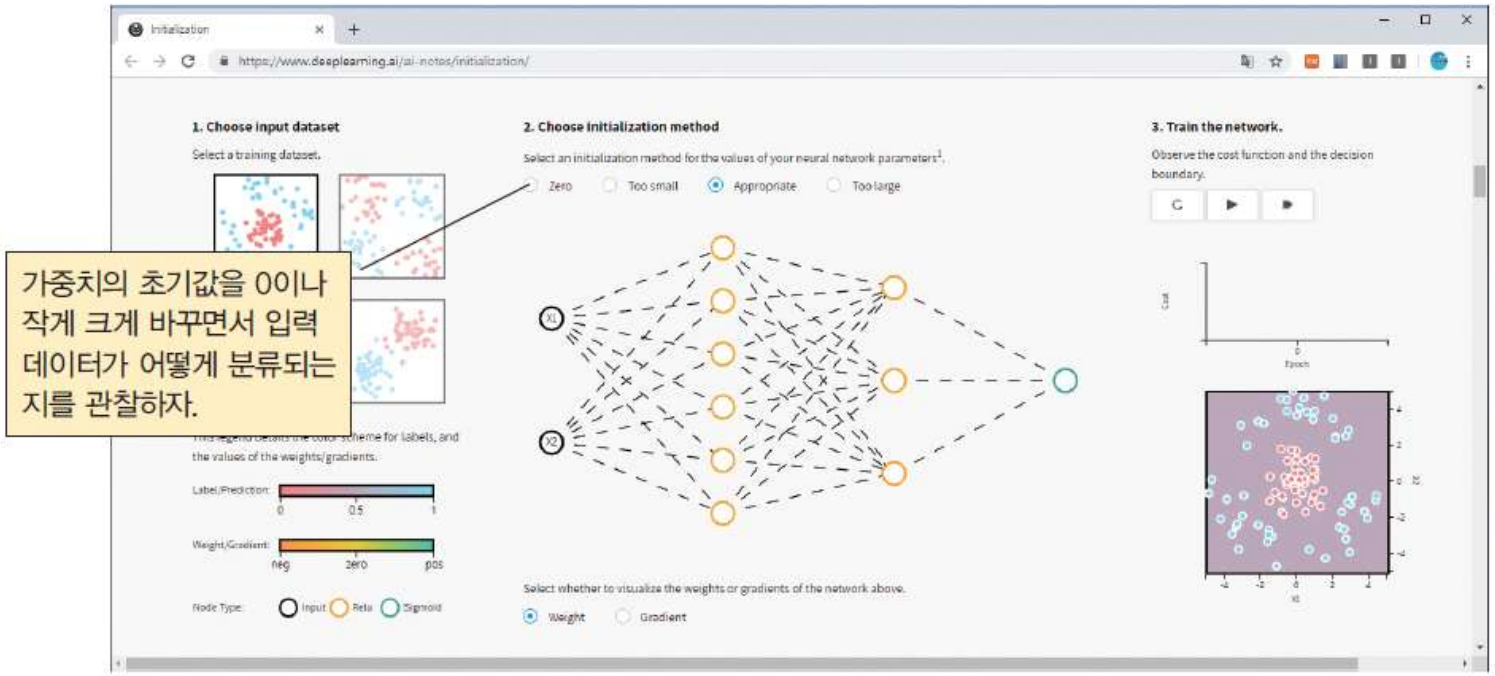

# 범주형 데이터 처리

- 입력 데이터 중에는 “male”, “female”과 같이 카테고리 (Category)를 가지는 데이터들이 아주 많다. -> 숫자로 바꾸어야 한다.

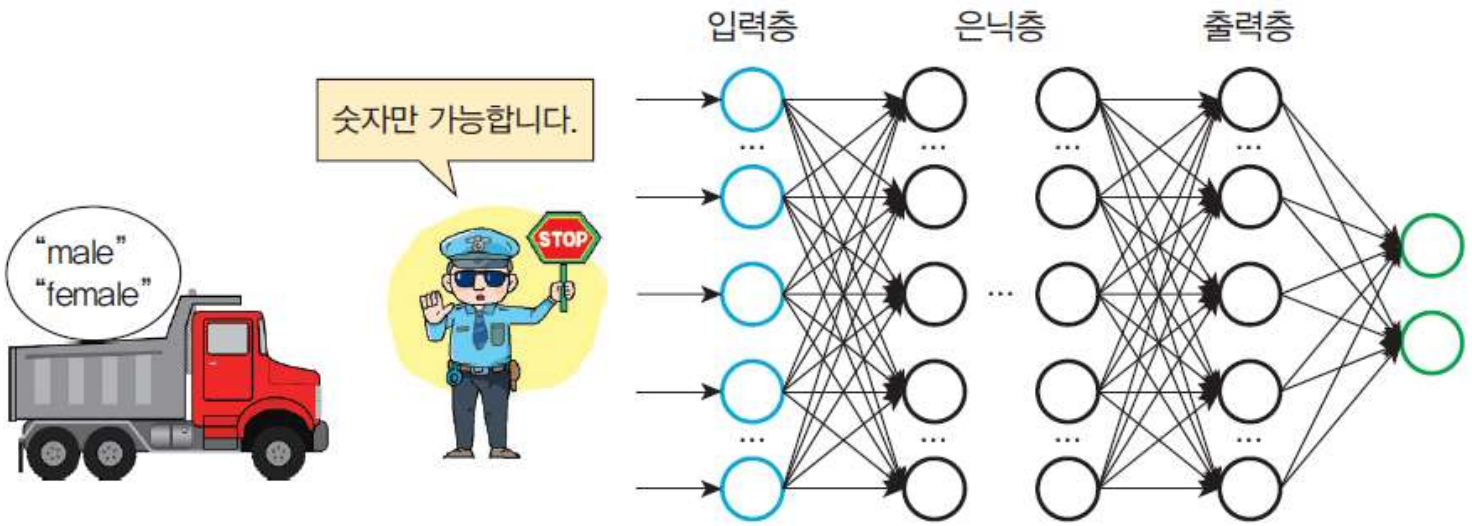

# 간단한 경우

```
for ix in train.index:
  if train.loc[ix, 'Sex']=="male":
          train.loc[ix, 'Sex']=1
  else:
          train.loc[ix, 'Sex']=0
```

# 일반적인 범주형 데이터 변환 방법

- 범주형 변수를 인코딩하는 **3**가지 방법
  - 정수 인코딩**(Integer Encoding):** 각 레이블이 정수로 매핑되는 경우.
  - 원-핫 인코딩**(One Hot Encoding):** 각 레이블이 이진 벡터에 매핑되는 경우.
  - 임베딩**(Embedding):** 범주의 분산된 표현이 학습되는 경우이다.

자연어 처리에서 설명

# 정수 인코딩

- sklearn 라이브러리가 제공하는 Label Encoder 클래스를 사용

int_encoding.py

이것만 바뀌는 예제

```
import numpy as np
X = np.array([['Korea', 44, 7200],
              ['Japan', 27, 4800],
              ['China', 30, 6100]])

from sklearn.preprocessing import LabelEncoder
labelencoder = LabelEncoder()
X[:, 0] = labelencoder.fit_transform(X[:, 0])
print(X)
```

```
[['2' '44' '7200']
['1' '27' '4800']
['0' '30' '6100']]
```

# 원-핫 인코딩

- 원-핫 인코딩은 단 하나의 값만 1이고 나머지는 모두 0인 인코딩을 의미한다. -> 아주 많이 사용된다.

| Country | Age | Salary |
|---|---|---|
| Korea | 38 | 7200 |
| Japan | 27 | 4800 |
| China | 30 | 3100 |

| Korea | Japan | China | Age | Salary |
|---|---|---|---|---|
| 1 | 0 | 0 | 38 | 7200 |
| 0 | 1 | 0 | 27 | 4800 |
| 0 | 0 | 1 | 30 | 3100 |

# 원-핫 인코딩

one_hot_A.py

```
import numpy as np
X = np.array([['Korea', 44, 7200],
              ['Japan', 27, 4800],
              ['China', 30, 6100]])

from sklearn.preprocessing import OneHotEncoder
onehotencoder = OneHotEncoder()

# 원하는 열을 뽑아서 2차원 배열로 만들어서 전달하여야 한다.
XX = onehotencoder.fit_transform(X[:,0].reshape(-1,1)).toarray()
print(XX)

X = np.delete(X, [0], axis=1)              # 0번째 열 삭제
X = np.concatenate((XX, X), axis = 1)  # X와 XX를 붙인다.
print(X)
```

```
[[0. 0. 1.]
 [0. 1. 0.]
 [1. 0. 0.]]
[['0.0' '0.0' '1.0' '44' '7200']
 ['0.0' '1.0' '0.0' '27' '4800']
 ['1.0' '0.0' '0.0' '30' '6100']]
```

# 원-핫 인코딩(케라스 사용)

- 원-핫 인코딩은 케라스의 to_categorical()을 호출해서도 만들 수 있다.-> 아주 많이 사용된다.

**one_hot(keras)_A.py**

```
class_vector =[2, 6, 6, 1]

from tensorflow.keras.utils import to_categorical
output = to_categorical(class_vector, num_classes = 7, dtype ="int32")
print(output)
```

```
[[0 0 1 0 0 0 0]
 [0 0 0 0 0 0 1]
 [0 0 0 0 0 0 1]
 [0 1 0 0 0 0 0]]
```

# 원-핫 인코딩 (케라스 사용-mnist )

```
import tensorflow as tf
mnist = tf.keras.datasets.mnist

(x_train, y_train),(x_test, y_test) = mnist.load_data()
print(x_train.shape,y_train.shape)
y_train[:10]

y_train_one_hot = to_categorical(y_train, num_classes = 10)  #, dtype ="int32")
y_train_one_hot.shape
y_train_one_hot[:10]
```

```
array([[0, 0, 0, 0, 0, 1, 0, 0, 0, 0],
       [1, 0, 0, 0, 0, 0, 0, 0, 0, 0],
       [0, 0, 0, 0, 1, 0, 0, 0, 0, 0],
       [0, 1, 0, 0, 0, 0, 0, 0, 0, 0],
       [0, 0, 0, 0, 0, 0, 0, 0, 0, 1],
       [0, 0, 1, 0, 0, 0, 0, 0, 0, 0],
       [0, 1, 0, 0, 0, 0, 0, 0, 0, 0],
       [0, 0, 0, 1, 0, 0, 0, 0, 0, 0],
       [0, 1, 0, 0, 0, 0, 0, 0, 0, 0],
       [0, 0, 0, 0, 1, 0, 0, 0, 0, 0]])
```

# 데이터 정규화

- 신경망은 일련의 선형 조합과 비선형 활성화 함수를 통해 이러한 차이가 나는 입력을 결합하여 학습하게 되므로 각 입력과 관련된 매개변수도 서로 다른 범위를 가지면서 학습된다.

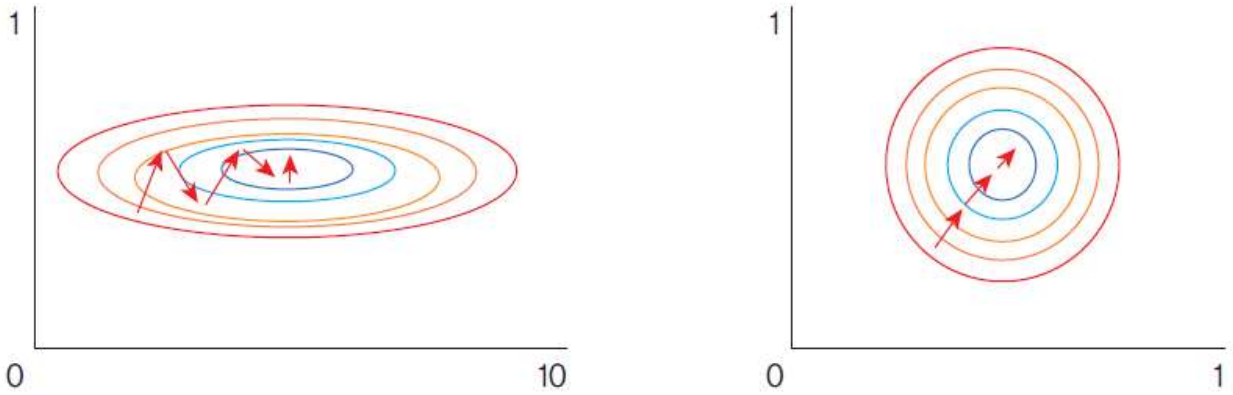


특징값의 범위가 다른 경우

특징값이 [0, 1]에서 움직이는 경우

그림 8-11 데이터 정규화의 영향

# 데이터 정규화 (Normalization)

- 부동 소수점 숫자 정밀도와 관련된 문제를 피하기 위해, 입력 값이 대략 -1.0에서 1.0 범위에 있도록 하는 것이 좋다

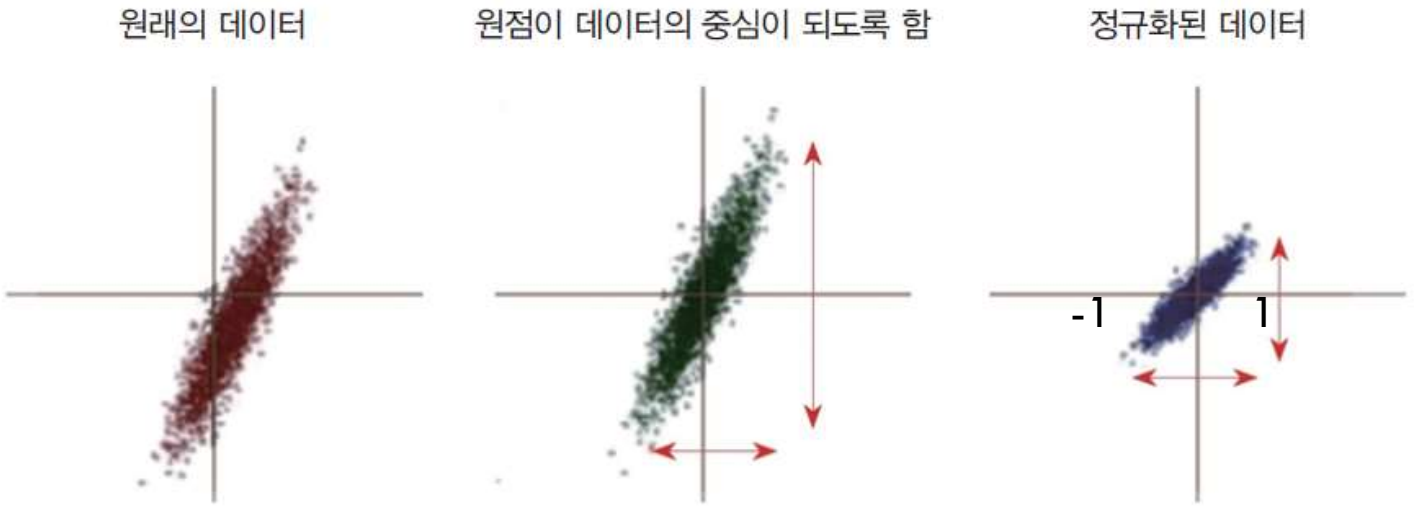


$$x_j' = \frac{x_j - \mu_j}{\sigma_j}$$

# 예제

- 사람의 나이, 성별, 연간 수입을 기준으로, 선호하는 자동차의 타입(세단 아니면 SUV)을 예측할 신경망을 만들고 싶다고 가정하자

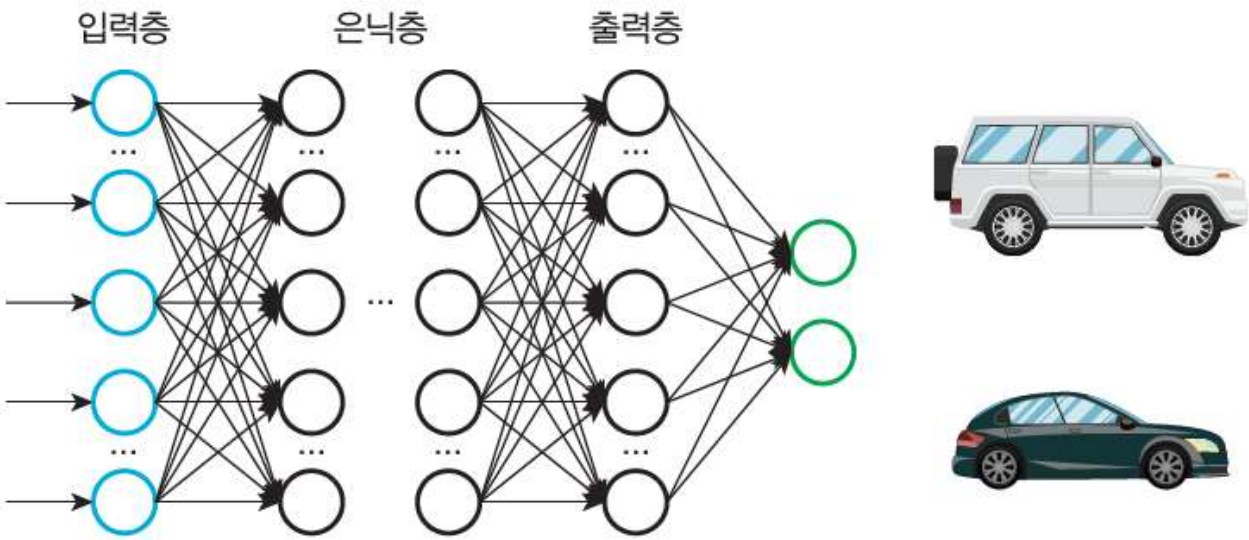

# 훈련 데이터 정규화

범주형 데이터

| | | | | |
|---|---|---|---|---|
| [0] | 30 | male | 3800 | SUV |
| [1] | 36 | female | 4200 | SEDAN |
| [2] | 52 | male | 4000 | SUV |
| [3] | 42 | female | 4400 | SEDAN |

정규화 필요

| | | | | | |
|---|---|---|---|---|---|
| [0] | -1.23 | -1.0 | -1.34 | (1.0 | 0.0) |
| [1] | -0.49 | 1.0 | 0.45 | (0.0 | 1.0) |
| [2] | 1.48 | -1.0 | -0.45 | (1.0 | 0.0) |
| [3] | 0.25 | 1.0 | 1.34 | (0.0 | 1.0) |

# sklearn의 데이터 정규화 방법 - MinMaxScaler

$$X\_std = (X - X.min(axis=0)) / (X.max(axis=0) - X.min(axis=0))$$

$$X\_scaled = X\_std * (max - min) + min$$

**minmax_A.py**

```
from sklearn.preprocessing import MinMaxScaler
data = [[-1, 2], [-0.5, 6], [0, 10], [1, 18]]

scaler = MinMaxScaler()
scaler.fit(data)                    # 최대값과 최소값을 알아낸다.
print(scaler.transform(data))       # 데이터를 변환한다.
```

```
[[0.   0.  ]
 [0.25 0.25]
 [0.5  0.5 ]
 [1.   1.  ]]
```

# sklearn의 데이터 정규화 방법 - StandardScaler

```
# StandardScaler()
from sklearn.preprocessing import StandardScaler
data = [[-1, 2], [-0.5, 6], [0, 10], [1, 18]]
# data = [[-1, 2, 7], [-0.5, 6, 3], [0, 10, -2], [1, 18, 6]]

scaler = StandardScaler()
scaler.fit(data)                    # 평균=0, 분산=std 로 데이터 변경
print(scaler.transform(data))
```

```
[[-1.18321596 -1.18321596]
 [-0.50709255 -0.50709255]
 [ 0.16903085  0.16903085]
 [ 1.52127766  1.52127766]]
```

# 케라스의 데이터 정규화 방법 - Normalization

- 데이터 정규화가 필요하면 Normalization 레이어를 중간에 넣으면 된다.

**normalization.py**

```
>>> adapt_data = np.array([[1.], [2.], [3.], [4.], [5.]], dtype=np.float32)
>>> input_data = np.array([[1.], [2.], [3.]], np.float32)
>>> layer = Normalization()
>>> layer.adapt(adapt_data)
>>> layer(input_data)
<tf.Tensor: shape=(3, 1), dtype=float32, numpy=
array([[-1.4142135 ],
       [-0.70710677],
       [ 0.        ]], dtype=float32)>
```

# 과잉 적합과 과소 적합

- 과잉 적합(over fitting)은 지나치게 훈련 데이터에 특화돼 실제 적용 시 좋지 못한 결과가 나오는 것을 말한다.

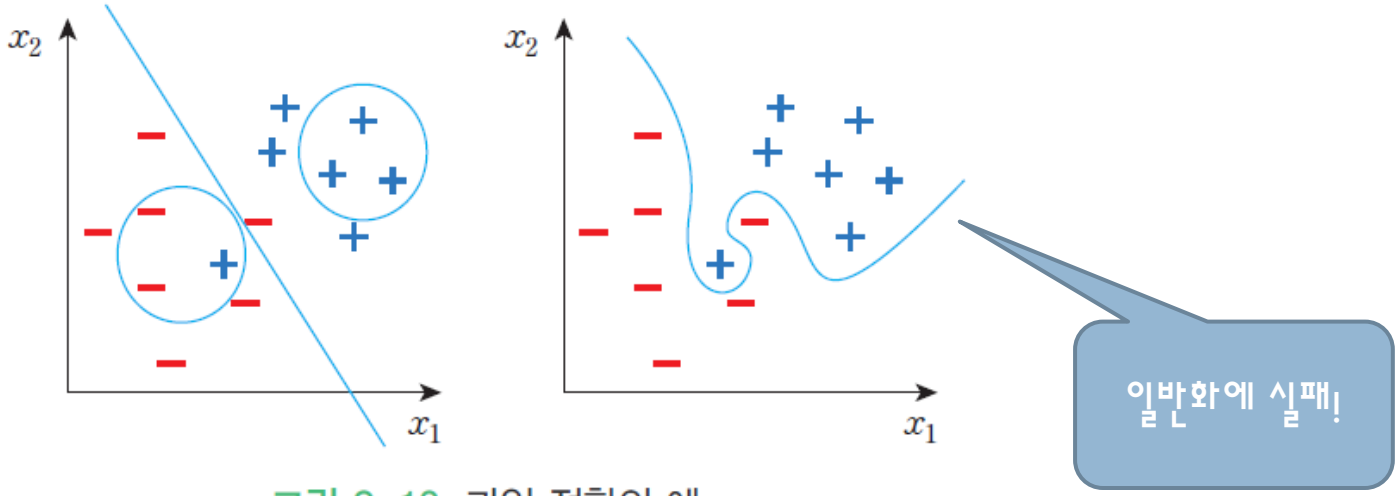


그림 8-13 과잉 적합의 예

# 과잉 적합 (overfitting)을 아는 방법

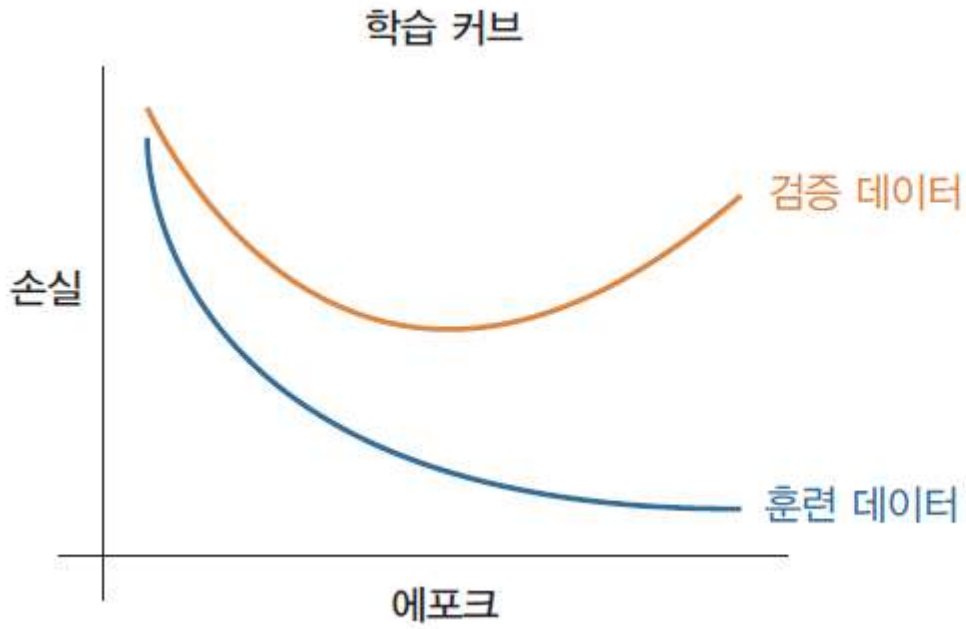


# 과잉 적합의 예

- 영화 리뷰를 분류하는 문제를 생각해보자. IMDB 사이트는 영화에 대한 리뷰가 올라가 있는 사이트이다.
- 영화 리뷰를 입력하면 리뷰가 긍정적인지 부정적인지를 파악하는 신경망을 구현해보자

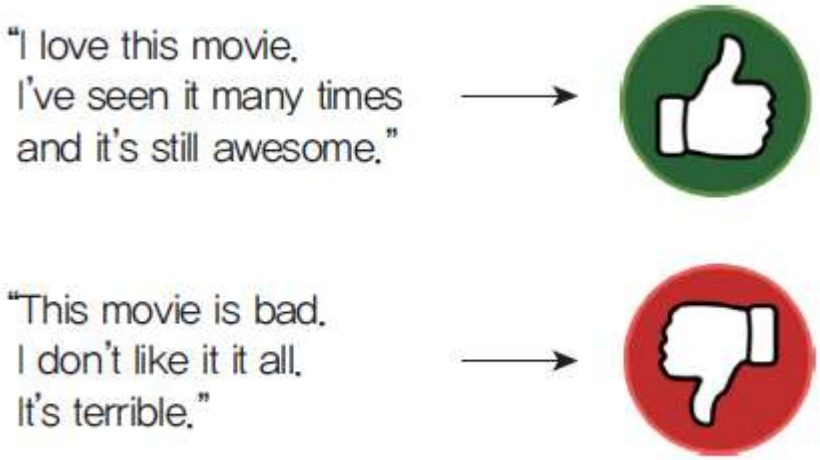

# IMDB 리뷰가 긍정적인지 부정적인지를 파악

```
import numpy as numpy
import tensorflow as tf
import matplotlib.pyplot as plt

# 데이터 다운로드
(train_data, train_labels), (test_data, test_labels) = \
    tf.keras.datasets.imdb.load_data( num_words=1000)
    # imdb.data_load()의 인자로 num_words를 사용하면 이 데이터에서 등장 빈도 순위로
    # 몇 등까지의 단어를 사용할 것인지를 의미

# 원-핫 인코딩으로 변환하는 함수
def one_hot_sequences(sequences, dimension=1000):
    results = numpy.zeros((len(sequences), dimension))
    for i, word_index in enumerate(sequences):
        results[i, word_index] = 1.
    return results

train_data = one_hot_sequences(train_data)
test_data = one_hot_sequences(test_data)
```

```
# 신경망 모델 구축
model = tf.keras.Sequential()
model.add(tf.keras.layers.Dense(16, activation='relu', input_shape=(1000,)))
model.add(tf.keras.layers.Dense(16, activation='relu'))
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))

model.compile(loss='binary_crossentropy', optimizer='adam',
              metrics=['accuracy'])

# 신경망 훈련, 검증 데이터 전달
history = model.fit(train_data,
                    train_labels,
                    epochs=20,
                    batch_size=512,
                    validation_data=(test_data, test_labels),
                    verbose=2)
```

```
# 훈련 데이터의 손실값과 검증 데이터의 손실값을 그래프에 출력
history_dict = history.history
loss_values = history_dict['loss']                  # 훈련 데이터 손실값
val_loss_values = history_dict['val_loss']          # 검증 데이터 손실값
acc = history_dict['accuracy']                              # 정확도
epochs = range(1, len(acc) + 1)                     # 에포크 수

plt.plot(history.history['loss'])
plt.plot(history.history['val_loss'])
plt.title('Loss Plot')
plt.ylabel('loss')
plt.xlabel('epochs')
plt.legend(['train error', 'val error'], loc='upper left')
plt.show()
```

# 실행 결과

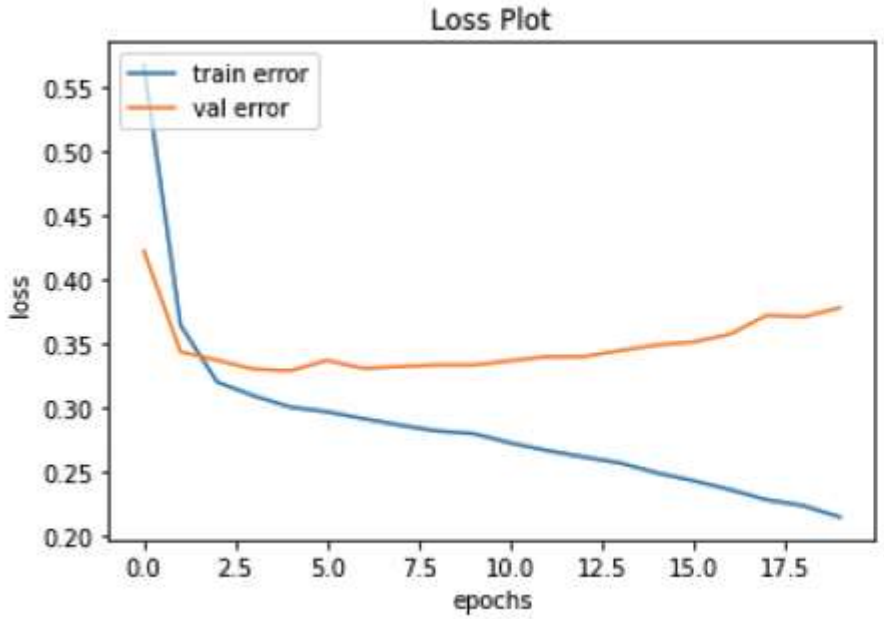
Loss Plot
train error
val error
loss
epochs
0.55
0.50
0.45
0.40
0.35
0.30
0.25
0.20
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5


훈련 데이터의 손실값은 줄어들지만 검증 데이터의 손실값은 오히려 증가하네요!

# 과잉 적합 방지 전략

- 조기 종료: 검증 손실이 증가하면 훈련을 조기에 종료한다.
- 가중치 규제 방법: 가중치의 절대값을 제한한다.
- **데이터 증강** 방법: 데이터를 많이 만든다.
- **드롭아웃** 방법: 몇 개의 뉴런을 쉬게 한다.

# 조기종료

- 검증 손실이 더 이상 감소하지 않는 것처럼 보일 때마다 훈련을 중단할 수 있다.이런 식으로 훈련을 중단하는 것을 조기 종료(Early Stopping)라고 한다.

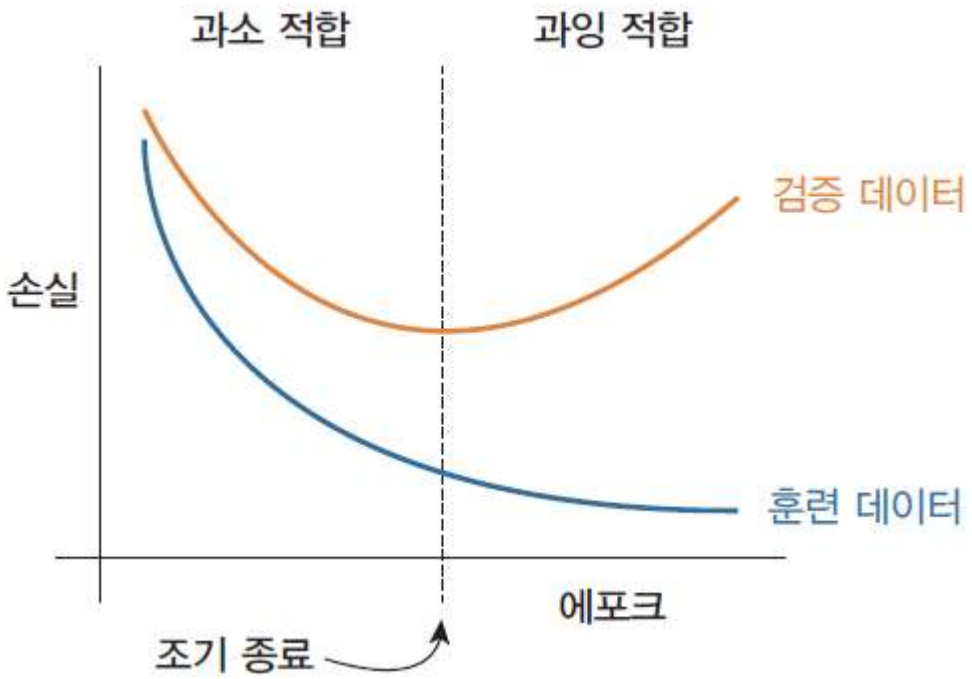

# 가중치 규제

- 가중치의 값이 너무 크면, 판단 경계선이 복잡해지고 과잉 적합이 일어난다는 사실을 발견하였다

$$Loss = Cost + \lambda \sum |W|$$

L1 규제

$$Loss = Cost + \lambda \sum W^2$$

L2 규제

```
# 신경망 모델 구축
model = tf.keras.Sequential()
model.add(tf.keras.layers.Dense(16,
  kernel_regularizer=tf.keras.regularizers.l2(0.001),
  activation='relu', input_shape=(1000,)))
model.add(tf.keras.layers.Dense(16,
  kernel_regularizer=tf.keras.regularizers.l2(0.001),  activation='relu'))
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))
```

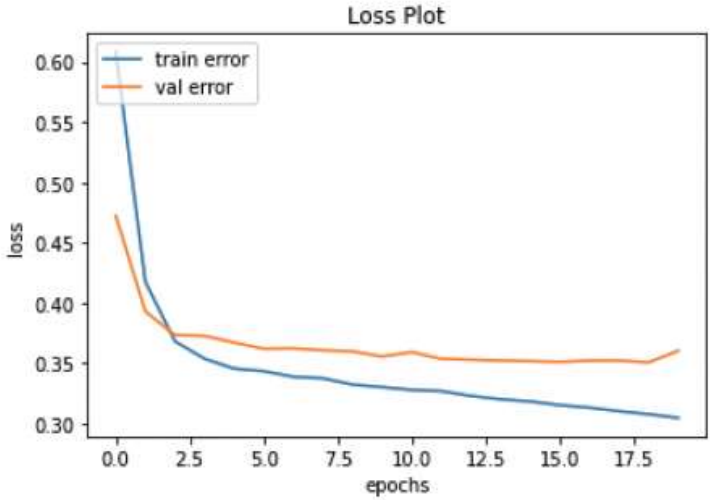


# 드롭 아웃 (dropout)

- 드롭아웃은 몇 개의 노드들을 학습 과정에서 랜덤하게 제외하는 것이다.

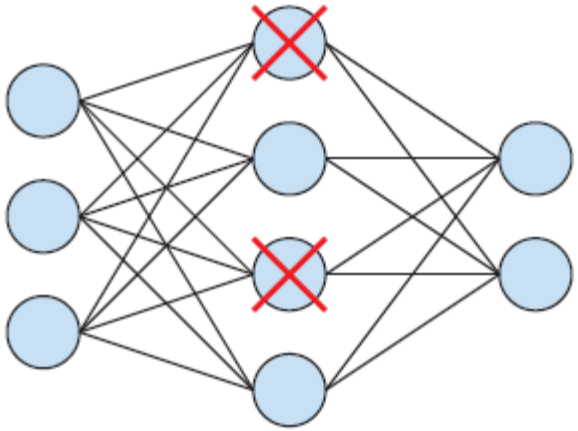

그림 8-14 드롭아웃

# Dropout

```
# 신경망 모델 구축
model = tf.keras.Sequential()
model.add(tf.keras.layers.Dense(16, activation='relu', input_shape=(10000,)))
model.add(tf.keras.layers.Dropout(0.5))
model.add(tf.keras.layers.Dense(16, activation='relu'))
model.add(tf.keras.layers.Dropout(0.5))
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))
```

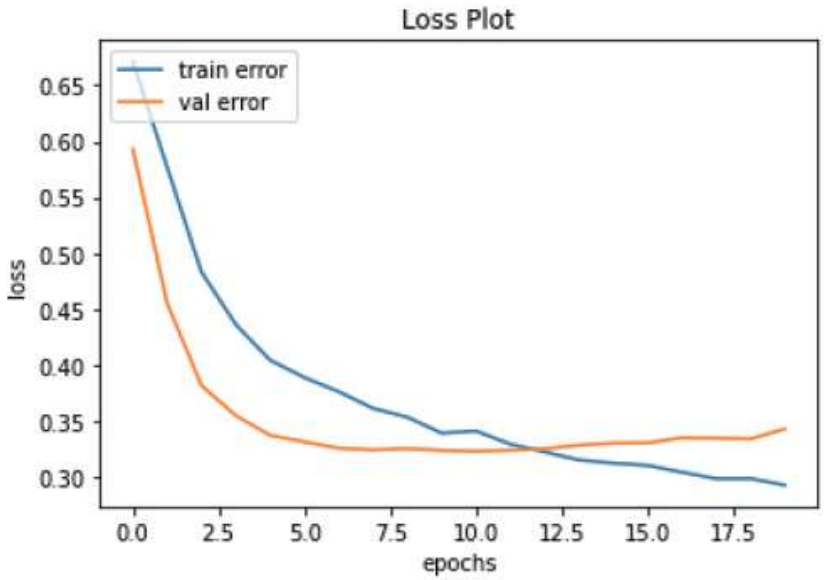

# 데이터 증강 방법 (data augmentation)

- 데이터 증강(data augmentation) 방법은 소량의 훈련 데이터에서 많은 훈련 데이터를 뽑아내는 방법이다.

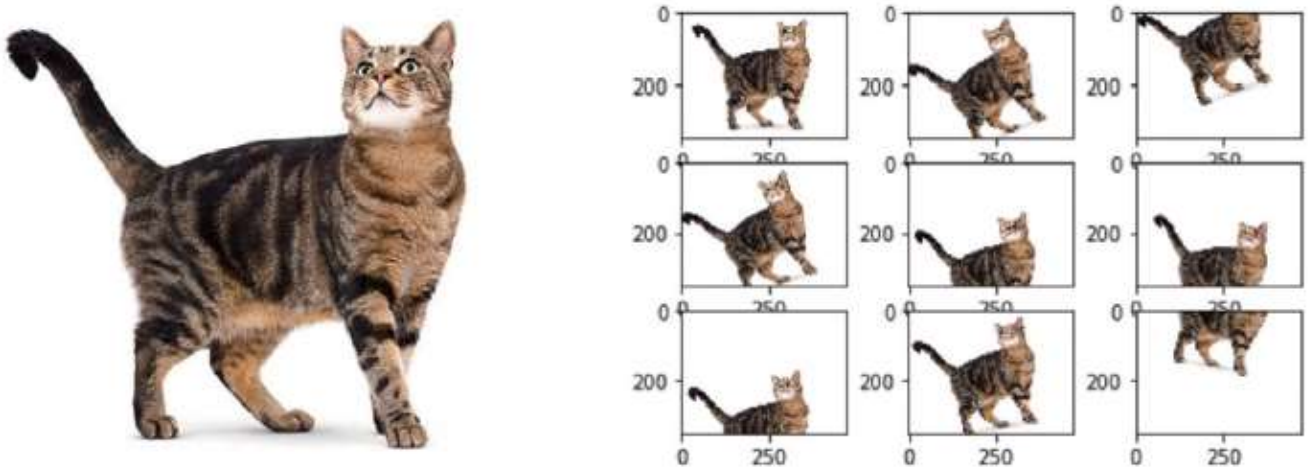


그림 8-15 데이터 증강 방법

# 앙상블

- 앙상블(ensemble)은 여러 전문가를 동시에 훈련시키는 것과 같다. 이 방법은 동일한 딥러닝 신경망을 N개를 만드는 것이다.
- 각 신경망을 독립적으로 학습시킨 후에 마지막에 합치는 것이다.

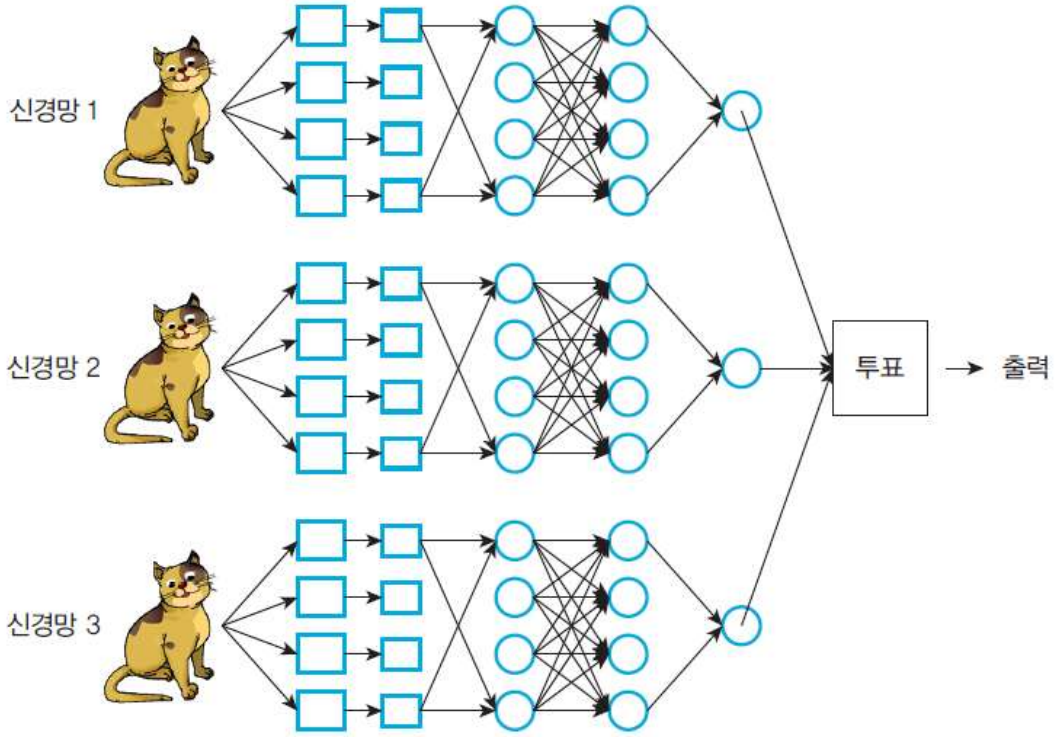

# 예제: MNIST 필기체 숫자 인식

- 우리는 7장에서 MNIST 숫자를 MLP로 인식해본 경험이 있다. 동일한 데이터 세트에 대하여 이번에는 심층 신경망을 사용해보자. 얼마나 정확도가 증가할까?

**mnist_dnn_A.py**

```
import matplotlib.pyplot as plt
import tensorflow as tf

mnist = tf.keras.datasets.mnist

(x_train, y_train),(x_test, y_test) = mnist.load_data()
x_train, x_test = x_train / 255.0, x_test / 255.0

model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Flatten(input_shape=(28,28)))
model.add(tf.keras.layers.Dense(512, activation='relu'))
model.add(tf.keras.layers.Dropout(0.2))
model.add(tf.keras.layers.Dense(10, activation='softmax'))
```

# 예제: MNIST 필기체 숫자 인식

```
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(x_train, y_train, epochs=5)
model.evaluate(x_test, y_test)
```

```
Epoch 1/5
60000/60000 [==============================] - 7s 116us/sample - loss: 0.2205 - acc: 0.9348
Epoch 2/5
60000/60000 [==============================] - 7s 110us/sample - loss: 0.0969 - acc: 0.9700
Epoch 3/5
60000/60000 [==============================] - 7s 109us/sample - loss: 0.0678 - acc: 0.9785
Epoch 4/5
60000/60000 [==============================] - 6s 108us/sample - loss: 0.0529 - acc: 0.9834
Epoch 5/5
60000/60000 [==============================] - 7s 108us/sample - loss: 0.0428 - acc: 0.9859
10000/10000 [==============================] - 0s 43us/sample - loss: 0.0645 - acc: 0.9795
```

# 예제: 패션 아이템 분류

- 이번 절에서는 텐서플로우 튜토리얼에 나오는 패션 아이템을 심층 신경망으로 분류하는 코드를 살펴보자.
(https://www.tensorflow.org/tutorials/keras/basic_classification)

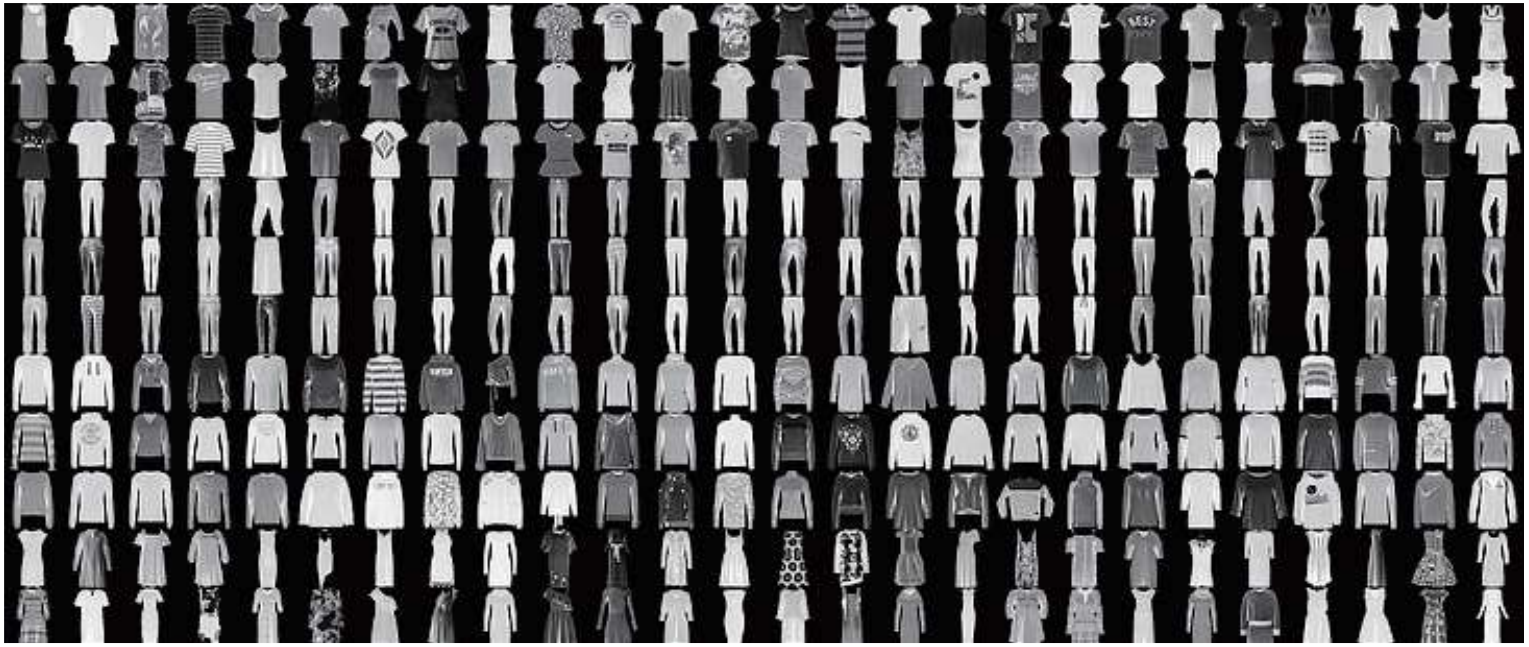

# 데이터 세트

- 이미지는 28x28 크기이고 픽셀 값은 0과 255 사이의 값이다. 레이블(label)은 0에서 9까지의 정수로서 패션 아이템의 범주를 나타낸다.

| 레이블 | 범주 |
|---|---|
| 0 | T-shirt/top |
| 1 | Trouser |
| 2 | Pullover |
| 3 | Dress |
| 4 | Coat |
| 5 | Sandal |
| 6 | Shirt |
| 7 | Sneaker |
| 8 | Bag |
| 9 | Ankle boot |

# 하나의 데이터

- plt.imshow(train_images[0])

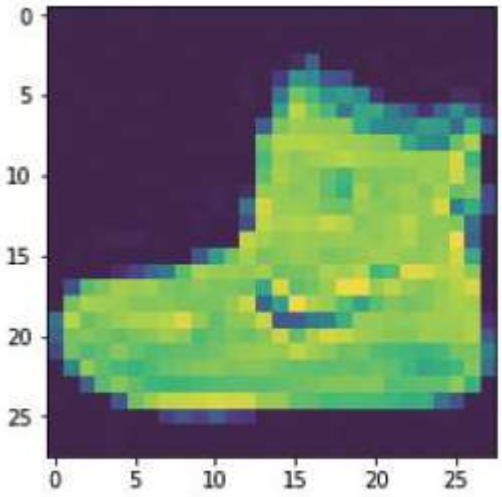

# 예제: 패션 아이템 분류

fashion_A.py

```
import tensorflow as tf
from tensorflow import keras
import numpy as np
import matplotlib.pyplot as plt
from tensorflow.keras import datasets, layers, models

fashion_mnist = keras.datasets.fashion_mnist
(train_images, train_labels), (test_images, test_labels) = fashion_mnist.load_data()

plt.imshow(train_images[0])

train_images = train_images / 255.0
test_images = test_images / 255.0
```

# 예제: 패션 아이템 분류

```
model = models.Sequential()
model.add(layers.Flatten(input_shape=(28, 28)))
model.add(layers.Dense(128, activation='relu'))
model.add(layers.Dense(10, activation='softmax'))

model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

model.fit(train_images, train_labels, epochs=5)

test_loss, test_acc = model.evaluate(test_images, test_labels)
print('정확도:', test_acc)
```

```
10000/10000 [==============================] - 0s 32us/sample - loss: 0.3560 -
acc: 0.8701
정확도: 0.8701
```

# 예제: 타이타닉 생존자 예측하기

생존자를 예측해봅시다. 어떤 부류의 사람들의 생존률이 높았을까요? 우리는 어떤 속성을 이용하여 이것을 예측할 수 있을까요?

Second

Third

Crew

# 라이브러리 적재

titanic_test.py

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
import tensorflow as tf
```

# 학습 데이터 다운로드

```
# 데이터 세트를 읽어들인다.
train = pd.read_csv("train.csv", sep=',')
test = pd.read_csv("test.csv", sep=',')

# 필요없는 컬럼을 삭제한다.
train.drop(['SibSp', 'Parch', 'Ticket', 'Embarked', 'Name',\
        'Cabin', 'PassengerId', 'Fare', 'Age'], inplace=True, axis=1)

# 결손치가 있는 데이터 행은 삭제한다.
train.dropna(inplace=True)
```

# 시각화

```
>>> df = train.groupby('Sex').mean()["Survived"]
>>> df.plot(kind='bar')
>>> plt.show()
```

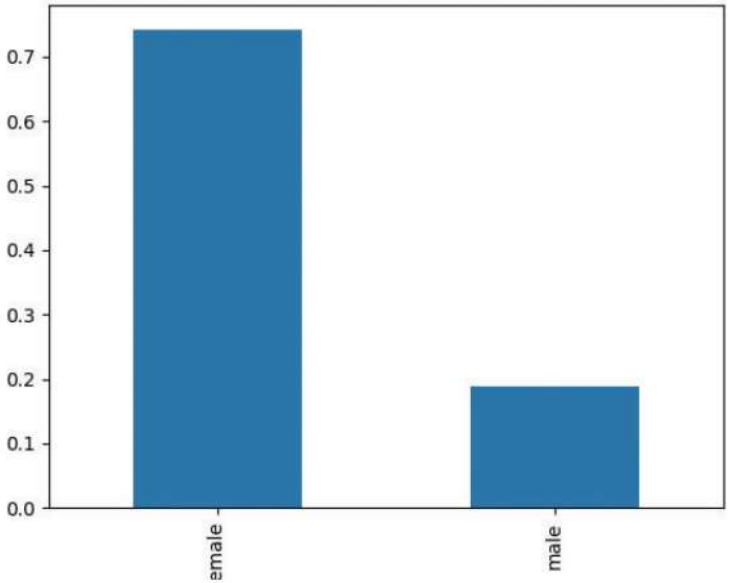


# 학습 데이터 정제

```
>>> train.drop(['SibSp', 'Parch', 'Ticket', 'Embarked', 'Name',\
       'Cabin', 'PassengerId', 'Fare', 'Age'], inplace=True, axis=1)


>>> train.head()
   Survived  Pclass     Sex
0         0       3    male
1         1       1  female
2         1       3  female
3         1       1  female
4         0       3    male
```

# 범주형 데이터를 정수로 변환

```
# 기호를 수치로 변환한다.
for ix in train.index:
    if train.loc[ix, 'Sex']=="male":
        train.loc[ix, 'Sex']=1
    else:
        train.loc[ix, 'Sex']=0

# 2차원 배열을 1차원 배열로 평탄화한다.
target = np.ravel(train.Survived)

# 생존여부를 학습 데이터에서 삭제한다.
train.drop(['Survived'], inplace=True, axis=1)
train = train.astype(float)     # 최근 소스에서는 float형태로 형변환하여야
```

컴퓨터는 숫자만 처리할 수 있다. 딥러닝은 0부터 1 사이의 실수만 처리 가능

교과서 소스에 추가

# 케라스 모델 구축

```
# 케라스 모델을 생성한다.
model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Dense(16, activation='relu', input_shape=(2,)))
model.add(tf.keras.layers.Dense(8, activation='relu'))
model.add(tf.keras.layers.Dense(1, activation='sigmoid'))

# 케라스 모델을 컴파일한다.
model.compile(loss='binary_crossentropy',
              optimizer='adam',
              metrics=['accuracy'])
# 케라스 모델을 학습시킨다.
model.fit(train, target, epochs=30, batch_size=1, verbose=1)
```

# 실행결과: 모델로 test data에 대한 예측

```
...
Epoch 29/30
891/891 [==============================] - 1s 753us/sample - loss: 0.4591 - acc:
0.7677
Epoch 30/30
891/891 [==============================] - 1s 753us/sample - loss: 0.4547 - acc:
0.7789
```

약 78% 정확도

- [DIY] test data에 대한 생/사 예측은?

# Summary

- DNN(deep neural networks)에서 사용하는 학습 알고리즘이다. DNN은 MLP(다층 퍼셉트론)에서 은닉층의 개수를 증가시킨 것이다.

- 예전의 MLP에서는 인간이 영상의 특징을 추출하여서 신경망에 제공하였다. DNN에서는 특징 추출 자체도 학습으로 수행할 수 있다.
- 그래디언트 소실 문제란 은닉층이 신경망에 많이 추가되면 손실 함수의 그래디언트가 0에 가까워지고 따라서학습이 되지 않는 현상이다. 시그모이드 함수가 범인이었다. 그래디언트 소실 문제를 해결하기 위하여 DNN에서는 활성화 함수로 **ReLU 함수**를 많이 사용한다.
- 교차 엔트로피(cross entropy)를 손실 함수로 많이 사용한다. 교차 엔트로피는 2개의 확률분포 간의 거리를 측정한 것이다.
- **가중치의 초기값은 작은 난수로 결정**되어야 한다. 가우시안 분포의 작은 난수를 사용하는 것이 좋다.
- 온라인 학습과 배치 학습의 중간에 있는 방법이 **미니 배치(mini barch)**이다. 이 방법에서는 훈련 데이터를 작은 배치들로 분리시켜서 하나의 배치가 끝날 때마다 학습을 수행하는 방법이다.

# Q & A